分类号 _____ 密级 _____

UDC _____ 编号 _____

上海交通大学
博士后研究报告

光学汤姆逊散射探针的非平衡态等离子体诊断

程先涛

工作完成日期 2024 年 3 月— 2026 年 7 月

报告提交日期 2026 年 8 月

中国（上海）

2026 年 8 月

Typeset by LaTeX 2$_\varepsilon$ at August 21, 2026

With package `PostDocRep` v0.1g of CTeX.ORG

光学汤姆逊散射探针的非平衡态等离子体诊断

Optical Thomson scattering for non-equilibrium plasma diagnostics.

博士后姓名 程先涛

流动站（一级学科）名称 物理

专　业（二级学科）名称 等离子体物理

研究工作起始时间 **2024** 年 **3** 月

研究工作期满时间 **2026** 年 **7** 月

单位名称 上海交通大学

报告提交日期 **2026** 年 **8** 月

摘 要

在惯性约束聚变等极端物理条件下，激光-等离子体相互作用可使电子速度分布函数显著偏离麦克斯韦平衡态，这对传统基于平衡假设的光学汤姆逊散射诊断构成了根本性挑战。为应对这一问题，本文系统发展了一套从非平衡散射光谱重建任意电子速度分布函数的理论框架与方法体系。在正演理论方面，通过引入傅里叶变换和围道积分，将电子极化率的计算转化为分布函数傅里叶分量的线性加权积分，在提升计算效率的同时揭示了反问题的病态性根源——非平衡态散射光谱对电子速度分布函数的高阶傅里叶成分具有极端敏感性。在反演策略方面，本文考察了两条独立的实现路径。梯度下降法以离散速度格点上的分布函数值为优化变量，通过迭代最小化理论光谱与实测光谱之间的残差；该方法通用灵活且便于引入物理约束，但受限于反问题的病态本质，收敛稳定性较差。数据驱动神经网络方法则构建大型深度神经网络，直接从光谱映射到分布函数的傅里叶系数，通过大规模训练样本学习从光谱到电子速度分布函数的映射关系；推理过程仅需单次前向传播，速度快且对噪声具有天然鲁棒性，但其泛化能力受限于训练集的覆盖范围。相较于梯度下降法，数据驱动的神经网络方法具有更好的稳定性和更强的重建能力。因此，本研究重点采用逆韧致吸收实验光谱与受激拉曼散射模拟光谱，对神经网络方法在实际场景中的重建能力进行了系统测试，取得了较好的验证效果。

Abstract

Under extreme physical conditions such as those encountered in inertial confinement fusion, laser-plasma interactions can drive the electron velocity distribution function (EVDF) to deviate significantly from the Maxwellian equilibrium, posing a fundamental challenge to conventional optical Thomson scattering (OTS) diagnostics that rely on the equilibrium assumption. To address this issue, this paper systematically develops a theoretical framework and methodology for reconstructing arbitrary EVDFs from non-equilibrium scattering spectra. On the forward modeling side, by introducing Fourier transform and contour integration, the calculation of electron susceptibility is transformed into a linearly weighted integral of the Fourier components of the EVDF, which not only improves computational efficiency but also reveals the root cause of the ill-posedness of the inverse problem—the extreme sensitivity of non-equilibrium scattering spectra to the high-order Fourier components of the EVDF. On the inversion side, two independent approaches are examined. The gradient descent method treats the discrete samples of the EVDF on a velocity grid as optimization variables and iteratively minimizes the residual between the theoretical and measured spectra; although flexible and capable of incorporating physical constraints, it suffers from poor convergence stability due to the ill-posed nature of the inverse problem. The data-driven neural network approach, in contrast, constructs a large deep neural network that directly maps the spectrum to the Fourier coefficients of the EVDF, learning the mapping from spectra to EVDFs through large-scale training samples. Inference requires only a single forward pass, offering fast speed and inherent robustness to noise, though its generalization capability is constrained by the coverage of the training set. Compared with the gradient descent method, the data-driven neural network approach exhibits better stability and stronger reconstruction capability. Therefore, this study focuses on testing the reconstruction performance of the neural network method in practical scenarios using experimental spectra from inverse bremsstrahlung and simulated spectra from

stimulated Raman scattering, achieving satisfactory validation results.

目录

摘要 ..... **i**

Abstract ..... **iii**

目录 ..... **v**

第一章 研究现状概述 **1**

1.1 光学汤姆逊散射探针的研究现状和应用 1

1.2 AI for Science 的研究现状 3

1.3 我们的方案 5

第二章 汤姆逊散射的基本理论 **9**

2.1 等离子体中的电磁散射 10

2.2 等离子体的谱密度函数 14

2.3 谱分解法计算介电系数 17

第三章 梯度下降法的反解方案 **21**

3.1 基于参数化基函数的先验约束方法 21

3.1.1 多高斯叠加模型及其数学形式 21

3.1.2 测试结果与模型局限 22

3.2 基于非参数化的全局优化方法 23

3.2.1 方法描述与优化流程 23

3.2.2 优化结果与病态性分析 23

3.2.3 正则化策略与工程困难 24

3.3 基于物理信息神经网络的求解方案 24

3.3.1 物理信息神经网络的基本原理 24

3.3.2 基于 PINN 的 EVDF 生成器设计 ····· 25
3.3.3 性能评估与局限性 ····· 26
3.4 小结与展望 ····· 26

第四章 数据驱动的反解方案 ····· **31**
4.1 数据集的构建策略 ····· 31
4.2 基于 DNN 的反演方案设计 ····· 32
4.2.1 网络架构和训练策略 ····· 32
4.2.2 模型架构对性能的影响 ····· 33
4.2.3 隐藏层节点数的影响 ····· 34
4.2.4 模型规模与性能的标度律 ····· 34
4.3 数据库的影响与误差预测 ····· 36
4.3.1 重建误差与最短距离的关系 ····· 36
4.4 不同测试集的泛化误差 ····· 37
4.4.1 五高斯叠加测试集 ····· 38
4.4.2 随机超高斯测试集 ····· 38
4.4.3 混合叠加测试集 ····· 38
4.5 数据库规模与生成策略对重建误差的影响 ····· 38

第五章 实际问题中的应用 ····· **43**
5.1 逆韧致吸收实验数据的重建 ····· 43
5.1.1 逆韧致吸收理论 ····· 43
5.1.2 实验参数和汤姆逊散射诊断 ····· 44
5.1.3 基于神经网络分析实验数据 ····· 45
5.2 受激拉曼散射超热电子的 PIC 模拟重建 ····· 47

第六章 结论 ····· **51**

致谢 ····· **53**

参考文献 ····· **55**

简历 **61**

表格

插图

1.1 八面体对称球形黑腔中的汤姆逊散射实验布局。黑腔由 32 路 3 加热激光驱动，总能量 80 kJ，包含间隔 1 ns 的 0.5 ns 预脉冲与 3 ns 主脉冲。探测光为 4 ，沿垂直方向从顶部激光注入孔（LEH）进入黑腔，能量 90 J，脉宽 3 ns，相对加热主脉冲延迟 0.3 ns。散射光经赤道方向 LEH 水平收集，散射角为 90°。该布局用于诊断黑腔等离子体的电子温度、密度等参数，为惯性约束聚变实验提供关键数据。[40] ····· 2

1.2 基于机器学习代理模型（ML-3D）的 KSTAR 集成 RMP 优化方案示意图。该方案利用 ML-3D 快速预测三维扭曲模对等离子体边界的影响，替代传统高成本数值模拟，实现实时反馈优化。[17] 3

1.3 梯度下降法方案流程图和数据驱动方案流程图. 基于梯度下降法的模型驱动重建：以理论光谱模型做正向计算，将待求 EVDF 参数化并初始化，计算模型光谱与实测光谱的残差，通过梯度下降迭代更新 EVDF 参数，直至残差收敛，最终输出重建的 EVDF。基于数据驱动重建：分为训练与推理两个阶段。训练阶段：利用大量已知 EVDF 样本，通过正演理论计算生成对应的汤姆逊散射光谱，构成 “光谱-真值 EVDF” 配对数据集；将光谱作为输入，EVDF 作为输出标签，训练神经网络最小化预测 EVDF 与真值之间的误差，使网络学会从光谱逆向映射到 EVDF 的非线性关系。推理阶段：将实测汤姆逊散射光谱直接输入训练好的神经网络，经前向计算即可即时输出重建的 EVDF，无需迭代求解，计算速度快、实时性强。与传统梯度下降法相比，神经网络方法在离线训练后，在线推理效率显著提升，且能处理复杂非线性映射。 6

2.1 围道积分的路径选择示意图. 当参数 $K < 0$ 时，被积函数在上半平面无穷远处发散，故无穷远围道取半径无穷大的下半圆弧，此时围道包围一个奇点（图中标记）；当 $K \geq 0$ 时，函数在下半平面无穷远处发散，无穷远围道改为上半圆弧，围道内不含奇点。箭头表示积分方向. ····· 17

2.2 对比了直接积分法与基于傅里叶变换的方法计算同一积分时的效率差异。横轴表示采样点数目：直接积分对应实空间采样点数，傅里叶方法对应傅里叶空间采样点数；纵轴表示计算误差。结果显示，在相同采样点数目下，基于傅里叶变换的方法通常能达到更低的误差，或只需更少采样点即可达到同等精度，从而体现出计算效率上的优势。 ····· 19

3.1 超高斯 EVDF(m=4.8) 的多高斯叠加模型重建示意图. 左图为实际汤姆逊散射光谱与重建光谱的对比，二者高度吻合，验证了反演算法的准确性；右图为实际 EVDF 与重建 EVDF 的对比，重建分布能较好地还原超高斯轮廓及边缘衰减行为。整体结果表明，该方法可有效用于非麦克斯韦分布下的电子速度分布函数重建。 · 22

3.2 非参数化的全局直接重建示意图. (a) 测量的汤姆逊散射离子光谱与重建离子光谱的对比，两者吻合良好；(b) 测量的电子光谱与重建电子光谱的对比，同样高度一致；(c) EVDF 在采样点上的傅里叶变换实部与虚部，作为优化过程中的中间量；(d) 最终重建得到的 EVDF。优化参数为 EVDF 在各采样点上的取值，通过对散射光谱的迭代拟合获得。 ····· 27

3.3 基于 PINN 从汤姆逊散射光谱（OTS）重建等离子体电子速度分布函数（EVDF）的流程图。首先，将待求的 EVDF 参数化，作为物理信息神经网络（PINN）的输出。随后，将预测的 EVDF 代入 OTS 正向物理模型，模拟计算理论散射光谱。将理论光谱与实际测量 OTS 之间的残差作为损失函数。通过反向传播更新网络参数，迭代优化使损失函数最小化。最终，当预测光谱与实验 OTS 足够吻合时，神经网络输出的 EVDF 即为重建结果。该流程将正向物理模型嵌入网络训练，无需显式反演，可有效利用先验物理约束，实现从 OTS 到 EVDF 的稳健重建。 ····· 28

3.4 基于 PINN 的电子速度分布函数（EVDF）重建结果。(a) 测量的汤姆逊散射离子光谱（实线）与 PINN 重建的离子光谱（虚线）对比，两者吻合良好；(b) 测量的红端电子光谱（实线）与重建电子光谱（虚线）对比；(c) 测量的蓝端电子光谱（实线）与重建电子光谱（虚线）对比，可见重建光谱在两端均能重现测量特征；(d) 真实 EVDF（蓝线）与 PINN 重建 EVDF（橙线）的对比，重建分布与真实分布基本一致，验证了 PINN 方法从散射光谱反演 EVDF 的有效性。 ····· 29

3.5 使用 PINN 对同一 EVDF 进行的 9 次随机重建结果。蓝线为重建 EVDF，红色虚线为设定的目标 EVDF。9 次中 5 次重建明显偏离目标（失败），其余 4 次吻合较好，说明重建结果对随机初始化敏感，稳定性不足。 ····· 29

4.1 基于深度神经网络（DNN）从汤姆逊散射光谱（OTS）重建等离子体电子速度分布函数（EVDF）的流程图。DNN 的输入分别为 OTS 的电子散射谱和离子散射谱。网络结构包含两层全连接隐藏层，用于提取谱线中的特征信息。输出端分为两部分：一是 EVDF 的傅里叶变换的实部与虚部，用于后续反演得到 EVDF；二是等离子体的离子温度与密度参数。该结果表明，所设计的 DNN 能够直接由散射光谱映射至 EVDF 的频域表示及关键等离子体参数，避免了传统迭代反演的高计算成本。 ····· 32

4.2 柱状图比较了两种 DNN 输出层设计下，模型在测试集上的重建误差分布。蓝色柱体表示输出层为 EVDF 的傅里叶变换（$F_e(K)$），红色柱体表示输出层直接为 EVDF（$f_e(v)$）。横坐标为重建 EVDF 的相对误差。结果显示，两种设计下的误差分布无明显区别，表明输出层采用傅里叶变换形式不会显著影响重建精度。 ····· 33

4.3 不同训练模式下 DNN 训练误差随训练轮次的变化。蓝线为完整模式，训练分为四个阶段：前 3000 轮学习率为 1×10^{-4}，随后 6000 轮降至 1×10^{-5}，之后 10000 轮降至 1×10^{-6}，最后 100000 轮降至 1×10^{-7}。红线为快速模式，仅将最后阶段训练轮数减少为 10000 轮，其余阶段与完整模式相同。结果显示，快速模式与完整模式的最终训练误差差别不大。 ····· 34

4.4 不同神经网络训练后的损失值对比，包括 CNN 以及隐藏层数为 2、5、8、12 的 DNN（分别标记为 DNN-2、DNN-5、DNN-8、DNN-12）。插图展示了使用 DNN-2 与 CNN 重建的 EVDFs（电子速度分布函数）的比较结果。 ····· 35

4.5 不同隐层单元数配置下双层 DNN 的性能对比。横轴为第一层单元数，纵轴为第二层单元数，颜色表示模型性能。所有网络总参数数固定为 10^6，展示了在相同参数预算下，隐层分配对性能的影响。 ····· 36

4.6 重建 EVDF 的预测误差与实际误差的关系 (a) 横轴为重建 EVDF 的实际误差，纵轴为通过本文公式计算的预测误差。每个蓝点代表一个测试 EVDF；红色虚线为斜率为 1 的参考线，线上的样本表示预测误差等于实际误差。(b) 横轴为重建 EVDF 的实际误差，纵轴为预测误差与实际误差的比值；红色虚线同样表示预测误差等于实际误差。总体而言，若蓝点紧密围绕参考线或比值接近 1，则说明该误差预测公式能准确估计重建 EVDF 的误差；偏离程度则反映公式预测偏差的大小。 ····· 37

4.7 展示了不同策略生成 EVDF 时的重建相对误差。策略包括：5 个随机高斯函数、随机超高斯函数、以及随机超高斯函数与 5 个随机高斯函数的叠加。左侧子图给出各策略下的重建误差分布；右侧子图对比了实际误差与前文引入的预测误差，以验证预测方法的准确性。整体结果显示，叠加策略的相对误差特征介于两种单一策略之间，且预测误差能较好地反映真实重建误差的走势。 ··· 40

4.8 展示了训练集大小与模型在留出测试集上泛化误差之间的关系。(a) 和 (b) 分别对应两种不同策略生成的训练集。随着训练样本增加，误差总体下降，但下降速度与稳定性因策略而异，反映了数据生成方式对模型泛化性能的影响。 ····· 41

4.9 展示了在不同训练集生成策略下训练的神经网络模型，分别在各自留出测试集和随机超高斯测试集上的相对误差分布。图中每一列代表一种训练集生成策略，同一列的两个子图使用相同的训练集；第一行子图为留出测试集上的结果，第二行子图为随机超高斯测试集上的结果。通过比较同一列上下两行，可以评估模型对训练数据分布的依赖程度及其对超高斯分布的泛化能力；通过比较同一行不同列，可以分析不同训练集生成策略对误差分布的影响。 ····· 42

5.1 **TOP9 实验平台示意图。超声速喷嘴向靶室中心前方 1**.3 mm 处喷射氮氢混合气体。九束直径均为 850 m 的加热光束以近准对称方式对气体进行电离和加热，持续约 500 ps。随后 500 ps 内，单束泵浦光与 TOP9 光束（相对泵浦光具有波长偏移 Δ）同时开启，二者之间通过离子声波（IAW）介导能量转移。在此期间，可额外开启与 TOP9 近反向传播的加热光束，以增强朗登（Langdon）效应；这些附加光束因波长与几何配置，与泵浦光和 TOP9 的相互作用可忽略。最后 500 ps 内，仅保留 TOP9 光束，用于测量基线等离子体透射率。TOP9 最终入射至薄漫射片，透射信号由电荷耦合器件（CCD）相机及光纤耦合条纹相机记录（示例见插图）。实验通过上述时序，分阶段表征了多光束耦合、非局域加热及等离子体状态演化。[36] ····· 44

5.2 利用深度神经网络（DNN）与物理信息神经网络（PINN）重建实验测量光电子能谱（OTS）的结果。重建得到电子速度分布函数（EVDF）后，基于该 EVDF 理论计算对应的 OTS 光谱，并与实验测量值进行对比。(a–c) 分别给出 OTS 的离子谱、红端电子谱和蓝端电子谱。其中黑色圆点为实验数据，蓝色和红色实线分别为 DNN 和 PINN 的重建结果。(d) 为重建的 EVDF，蓝色和红色线同样分别来源于 DNN 与 PINN。通过对比可见，两种方法均能较好地再现实验 OTS 谱线，且 PINN 在约束物理规律后重建的 EVDF 与理论预期更为一致。 ····· 46

5.3 含热电子的电子速度分布函数（EVDF）重建。(a–c) 的纵轴为归一化电子数密度，速度分布最大值归一化为单位量。(a) 给出训练集中一个 EVDF 样本在增强前（蓝色曲线）与增强后（红色曲线）的变化，蓝、红阴影区域分别代表训练集所有样本增强前、后的平均 EVDF，增强处理在保持主体分布的同时，提高了高能尾部的统计代表性。(b) 比较了 PIC 模拟的 EVDF（蓝线）与分别基于增强数据（红线）和未增强数据（黑线）训练的 DNN 重建 EVDF，可见增强数据训练的 DNN 与模拟结果更为接近，尤其能更好地重现热电子区域。(c) 展示了使用增强数据库训练的 DNN 在不同时刻重建的 EVDF（红线）与 PIC 模拟结果（蓝线）的对比，红色阴影区为热电子贡献，重建分布在各时刻均能与模拟结果保持一致。(d) 给出了前向传播热电子的时间演化，其中蓝线和红线分别来自 PIC 模拟和 DNN 重建，两者在整体演化趋势和幅度上吻合良好。综上，该图表明基于增强数据库训练的 DNN 能够有效重建含热电子的 EVDF，并能较好捕捉其动态演化过程。 ····· 48

5.4 不同噪声水平下热电子数目预测相对误差的统计结果。红色曲线表示相对误差的均值，红色区域表示标准差；每个噪声水平下均基于 700 次不同的电子速度分布函数（EVDF）与随机噪声迭代计算获得。插图展示了蓝电子峰（e ）在噪声水平分别为 0、10%、20% 时的光学瞬态光谱（OTS）对比，用于直观显示噪声对谱形及后续热电子预测的影响。随着噪声水平增加，相对误差的均值与标准差均呈增大趋势，反映预测不确定性的累积。 ····· 50

第一章　研究现状概述

1.1　光学汤姆逊散射探针的研究现状和应用

光学汤姆逊散射凭借其主动式、高精度、非微扰的诊断特性，在激光惯性约束聚变研究中发挥着不可替代的作用。其诊断原理基于电子对探针光的弹性散射：当一束短波长激光穿越等离子体时，散射光谱的频移与展宽携带了电子的速度信息，而谱形的共振结构则反映了等离子体的集体响应。通过拟合动力学形状因子，OTS 能够同时给出电子温度、电子密度、等离子体流速和平均电离度等关键状态参数，这使得它成为黑腔等离子体状态精密诊断的标准方法[7, 41, 43]。在 ICF 实验与辐射流体模拟存在系统性偏差的背景下，OTS 提供了校验黑腔能量学模型、理解激光能量耦合过程的关键实验数据。

国内 OTS 技术的发展与神光系列激光装置的升级紧密同步。20 世纪 90 年代末，研究人员在星光　装置上首次开展 OTS 实验，验证了二倍频探针光的可行性 [1]。2003 年，神光　装置通过改造实现了四倍频探针光输出，在 kJ 级能量平台上开展了系统性的技术验证，获得了盘靶位型下系列空间位置的散射光谱，并用于电子热传导等基础物理问题的研究。此后，气袋靶大尺度等离子体平台的建立，使 OTS 得以在毫米级均匀等离子体中进行参数表征 [21]。2014 年，神光　原型装置正式具备四倍频 OTS 诊断能力，在 10kJ 级平台上首次针对充气黑腔开展了诊断实验，获得了腔内不同特征区域的散射光谱，标志着该技术与 ICF 靶物理的直接对接 [9]。2017 年，100kJ 激光装置建成并投入使用，OTS 随即在该装置上获得了充气六孔球腔内具有超高信噪比的全过程离子特征谱，光谱拟合结果显示黑腔内的电子热传导可能呈现非局域特征，这一发现对黑腔物理建模具有重要意义 [39, 40, 42]。

然而，OTS 在 ICF 环境中的应用面临着极为严峻的技术挑战。首先，散射信号极其微弱，对于典型的黑腔等离子体，收集到的散射光能量仅为入射探针光的约十亿分之一，而黑腔内同时存在着三倍频加热激光、受激散射光、韧致辐射等多种强干扰源，这些背景信号可以轻易湮没目标散射信号 [4, 32]。为了尽量避开这些干扰，探针光波长需要不断向深紫外方向延伸，目前普遍采用四倍频探针光 [4, 32]，但五倍频探针光由于倍频效率低下、深紫外光学元件传输

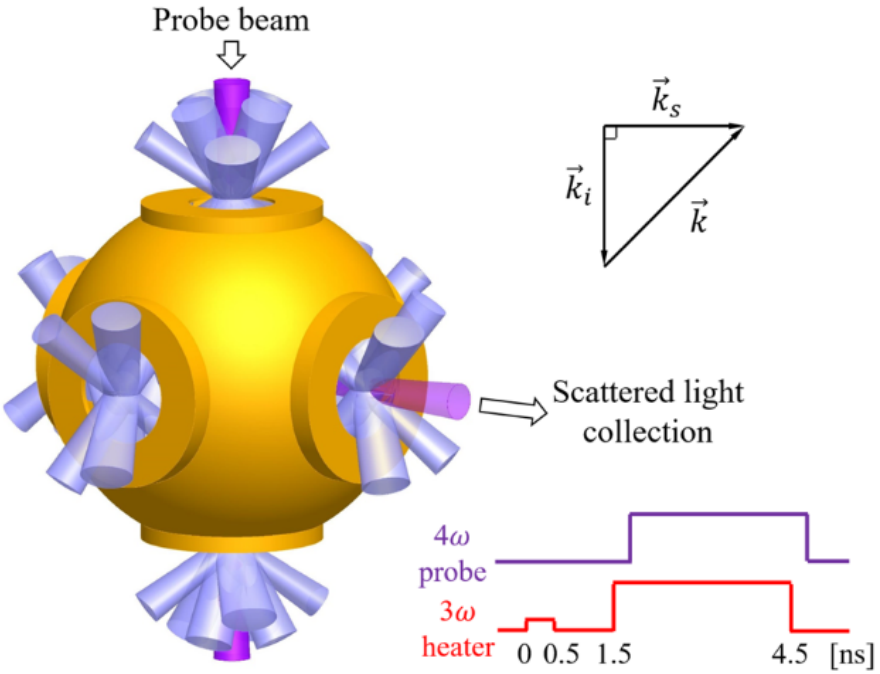


图 1.1: 八面体对称球形黑腔中的汤姆逊散射实验布局。黑腔由 32 路 3 加热激光驱动，总能量 80 kJ，包含间隔 1 ns 的 0.5 ns 预脉冲与 3 ns 主脉冲。探测光为 4 ，沿垂直方向从顶部激光注入孔（LEH）进入黑腔，能量 90 J，脉宽 3 ns，相对加热主脉冲延迟 0.3 ns。散射光经赤道方向 LEH 水平收集，散射角为 90°。该布局用于诊断黑腔等离子体的电子温度、密度等参数，为惯性约束聚变实验提供关键数据。[40]

损耗大等工程瓶颈，美国国家点火装置经过多年攻关后于 2024 年初宣布暂停相关研发 [30]。其次，黑腔等离子体的时空不均匀性对 OTS 诊断构成了实质性限制，诊断孔的辐射烧蚀缩孔效应可能使散射信号的出射通道被高温等离子体堵塞，有效测量窗口远短于探针光的脉宽；探针光在等离子体中的逆韧致吸收 [35] 和偏折效应 [6] 也会削弱到达探测区域的信号强度。此外，单支路离子特征谱难以实现电子密度与温度的有效解耦 [31]，而电子特征谱的强度比离子特征谱弱约两个量级且落入极深紫外波段，诊断难度极大。

面对上述挑战，OTS 技术正在向多维度、高精度的方向持续演进。多支路汤姆逊散射通过同时获取不同散射角度的离子谱与电子谱，有望实现电子密度与温度的联合解耦，大幅提升参数诊断精度 [8, 24, 28, 34]。超热相干汤姆逊散射则可直接诊断激光等离子体不稳定性所激发的强等离子体波，为研究受激散

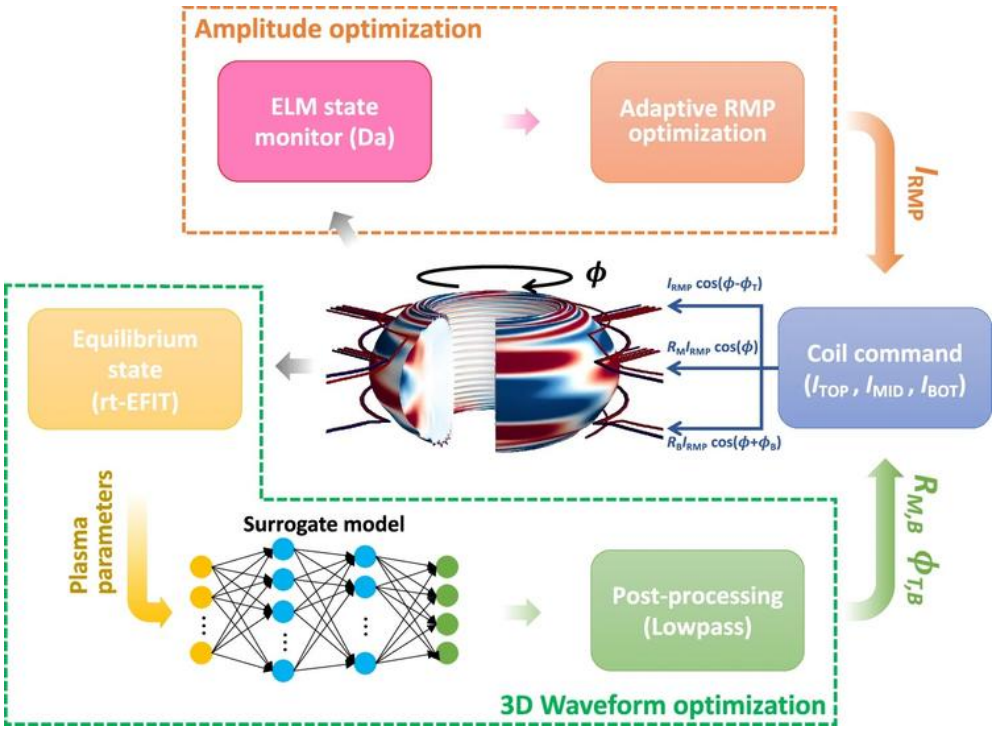


图 1.2: 基于机器学习代理模型（ML-3D）的 KSTAR 集成 RMP 优化方案示意图。该方案利用 ML-3D 快速预测三维扭曲模对等离子体边界的影响，替代传统高成本数值模拟，实现实时反馈优化。[17]

射等非线性物理过程提供了独特手段。随着神光系列装置诊断能力的不断提升和新诊断方法的逐步成熟，OTS 将在惯性约束聚变及其他高能量密度物理领域发挥更加深入的关键作用。

1.2　AI for Science 的研究现状

近年来，人工智能驱动的科学研究（AI for Science, AI4S）已从概念验证阶段迈向深度应用，成为重塑多学科研究范式的重要力量。在生物学领域，AlphaFold 将蛋白质结构预测精度推进至原子级别 [14]；在气象科学中，AI 模型已展现出超越传统数值预报的潜力 [2, 18]；在材料科学领域，AI 系统已成功发现数以万计的新型晶体材料与超导候选物 [26]。这些突破表明，AI 正在从纯粹的“计算加速器”演变为能够参与科学发现与理论构建的“认知协作者”。

在这一宏观背景下，深度神经网络（Deep Neural Network, DNN）[3] 与物理信息神经网络（Physics-Informed Neural Network, PINN）[5, 29] 作为两种代

表性的 AI 范式，在等离子体物理与可控核聚变研究中展现出日益重要的作用 [16, 22, 25]。DNN 由多层全连接神经元构成，通过大规模数据驱动的方式学习从输入到输出的高维非线性映射，其核心优势在于强大的函数逼近能力与端到端的自动化特征提取 [3]。然而，纯数据驱动的 DNN 往往面临训练数据不足、泛化能力受限以及“黑箱”可解释性差等问题。PINN 则提供了一种不同的思路——它将物理方程（如偏微分方程）作为软约束直接嵌入神经网络的损失函数，使模型在拟合数据的同时自动满足物理定律 [5, 29]。这一范式使得 PINN 在数据稀疏的场景下仍能保持物理一致性，且无需依赖大规模的标注数据集。

在聚变等离子体诊断领域，DNN 与 PINN 的融合应用正在快速推进。2025 年，普林斯顿大学团队在《Nature Communications》上报道了一种多模态超分辨率机器学习框架，利用其他诊断数据重建出高时间分辨率的汤姆逊散射（Thomson Scattering, TS）数据，从而揭示了边界局域模（ELMs）抑制过程中的精细等离子体动力学 [11]。同期，中国科学技术大学、中科院等离子体物理研究所与科大讯飞组成的 AIForScience 联合团队，基于 EAST 装置超万次放电实验数据训练了 PaMMA-Net 深度神经网络模型，实现了对等离子体磁测量演化的高精度预测 [23]。此外，迁移学习也被引入 TS 光谱分析——研究者通过在合成数据上预训练、在实验数据上微调的方式，有效缓解了实验数据稀缺的问题 [10]。在 PINN 方面，2025 年 IAEA 技术会议上已有报告系统探讨了 PINN 在托卡马克诊断测量分析中的潜力，涵盖平衡重建、剖面识别与层析成像等任务；同期发表的“Onion”模型架构则将物理信息通过乘法过程与物理信息损失函数（PILF）相结合，显著提升了线积分诊断的二维剖面重建精度 [37]。

聚焦于 OTS 光谱的 EVDF 反演这一具体问题，DNN 与 PINN 各自展现出不同的优势与局限。DNN 方案的核心优势在于推理速度——一旦训练完成，单次反演仅需毫秒量级，这为未来 OTS 的实时在线诊断提供了技术基础。然而，纯数据驱动的 DNN 面临着 sim-to-real gap 的挑战：训练数据基于理想化的物理模型生成（无噪声、理想光谱响应、参数均匀采样），而真实实验数据包含探测器噪声、有限光谱分辨率、背景辐射及等离子体时空不均匀性等复杂因素，导致模型在模拟数据上表现优异却可能在面对真实光谱时产生偏差 [10, 12, 27]。因此，用实验测量数据和 PIC 模拟结果作为独立的测试基准具有重要的验证意义——如果模型在这些“分布外”数据上仍能给出合理的重建结果，则说明模型确实学到了从光谱到 EVDF 的稳健映射关系，而非仅在高维空间中记忆了训练集附近的局部结构 [13]。

与 DNN 不同，PINN 在反演过程中直接比较重建 EVDF 对应的 OTS 光谱与目标光谱，因此天然地将物理前向模型作为约束融入优化，能够对光谱的每一个细节进行精确拟合。但也正因如此，PINN 对 OTS 光谱的极端敏感性使其在多数非麦克斯韦 EVDF 的反演中稳定性较差，且逐样本优化的方式导致推理时间远长于 DNN 的单次前向传播。两种方法各有所长：DNN 擅长快速、批量的泛化推理，PINN 则在追求光谱级精度的特定样本上具有优势，二者的有机结合可能是未来 OTS 非平衡 EVDF 反演的发展方向。

缩放定律（scaling law）的发现为这一领域提供了重要的理论指引——神经网络的性能随模型参数量与训练数据量的幂律关系而可预测地提升 [15, 33]。这意味着通过增加模型规模和训练数据覆盖范围，DNN 在 OTS 反演中的精度与泛化能力有望持续改善，为克服 sim-to-real gap 提供了可行的技术路径。随着聚变装置诊断数据规模的持续增长以及 DNN 与 PINN 融合方法的不断成熟，AI4S 有望在 OTS 光谱的实时、高精度反演中发挥日益关键的作用。

1.3　我们的方案

在惯性约束聚变等极端物理条件下，激光等离子体相互作用可使电子速度分布函数显著偏离麦克斯韦平衡态，这对传统基于平衡假设的汤姆逊散射诊断构成了根本性挑战。为此，我们从正演理论出发，发展了两种独立的反演方案——梯度下降法与数据驱动神经网络方法，并系统地比较了各自的适用性与局限性。

在正演理论方面，非平衡分布函数 $f_e(v)$ 与散射光谱的关系通过电子极化率 χ_e 的积分表达式建立。我们引入傅里叶变换将分布函数表示为 $F_e(K)$ 的叠加，并利用围道积分解析处理速度空间的奇异点，最终将 χ_e 化为 $F_e(K)$ 的线性加权积分。这一变换将正演计算效率提升了约三个量级，同时显式揭示了分布函数的高频分量对散射光谱的敏感性强弱，为理解反问题的病态性提供了数学基础。

在此基础上，我们考察了两种反演路径。梯度下降法将反演构造为优化问题：以离散速度格点上的分布函数值为变量，通过迭代最小化理论光谱与实测光谱之间的残差。该方法无需预先假设分布函数的具体形式，具有很好的通用性和灵活性，且可方便地引入非负性、归一化等物理约束。然而，由于其病态本质，优化过程对初始值高度敏感，容易在非物理解的空间震荡中陷入局部极值，

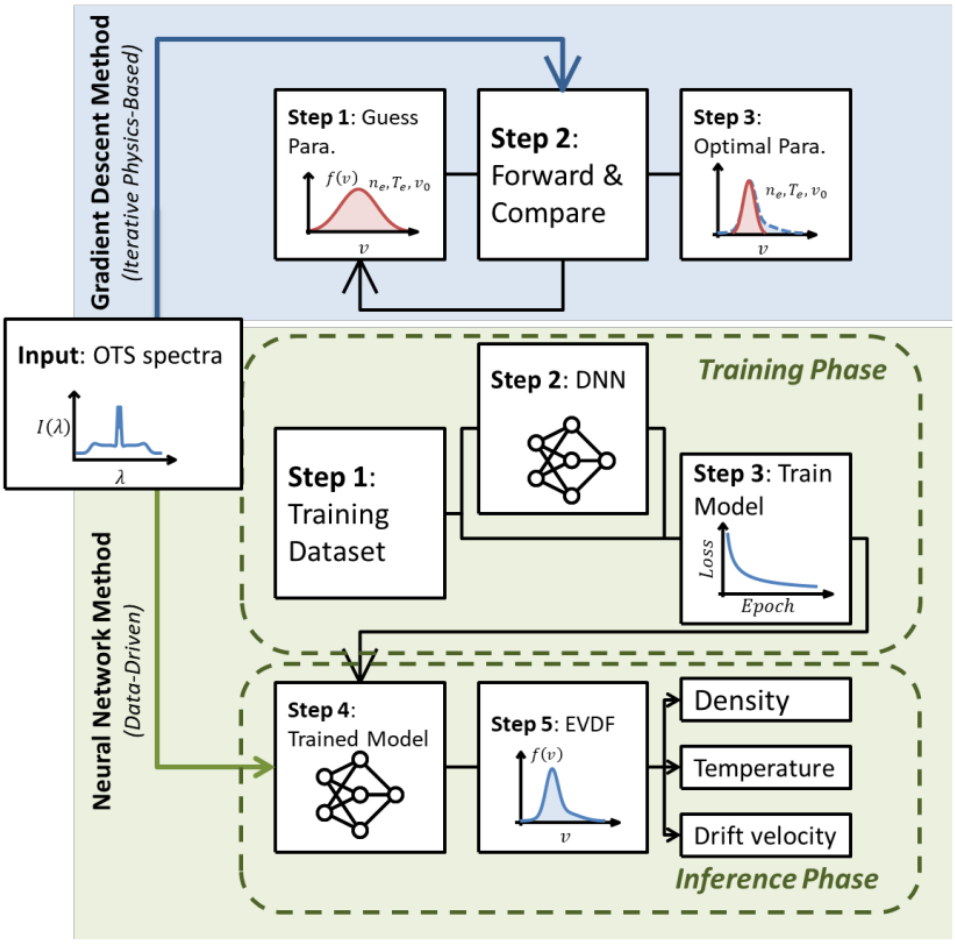


图 1.3: 梯度下降法方案流程图和数据驱动方案流程图. 基于梯度下降法的模型驱动重建：以理论光谱模型做正向计算，将待求 EVDF 参数化并初始化，计算模型光谱与实测光谱的残差，通过梯度下降迭代更新 EVDF 参数，直至残差收敛，最终输出重建的 EVDF。基于数据驱动重建：分为训练与推理两个阶段。训练阶段：利用大量已知 EVDF 样本，通过正演理论计算生成对应的汤姆逊散射光谱，构成“光谱-真值 EVDF”配对数据集；将光谱作为输入，EVDF 作为输出标签，训练神经网络最小化预测 EVDF 与真值之间的误差，使网络学会从光谱逆向映射到 EVDF 的非线性关系。推理阶段：将实测汤姆逊散射光谱直接输入训练好的神经网络，经前向计算即可即时输出重建的 EVDF，无需迭代求解，计算速度快、实时性强。与传统梯度下降法相比，神经网络方法在离线训练后，在线推理效率显著提升，且能处理复杂非线性映射。

收敛稳定性较差。第二种方案采用数据驱动的神经网络方法。我们构建并训练了一个大型深度神经网络，使其直接从输入光谱映射到分布函数的傅里叶系数。该网络以大规模随机生成的 EVDF 及其对应的理论光谱为训练样本，通过数据驱动的监督学习，将反演中所需的隐式正则化嵌入网络参数之中。一旦训练完成，推理过程仅需单次前向传播，速度快至毫秒量级，且具有天然的噪声鲁棒性。但其局限性在于：重建质量高度依赖于训练数据对目标函数空间的覆盖程度，当目标 EVDF 与训练集分布差异较大时，泛化误差可能显著增大。两种方法各有其适用场景：梯度下降法适用于先验信息较少、需要灵活引入特定约束的研究性分析；神经网络方法则适用于需要快速、批量处理的诊断场景。这两条技术路径构成了从非平衡 OTS 光谱到任意 EVDF 重建的系统性工具箱。

第二章　汤姆逊散射的基本理论

汤姆逊散射作为一种主动式等离子体诊断技术，其理论框架的建立经历了一个从单粒子图像到多粒子统计描述、从微观运动到宏观观测的逐步深化过程。该理论的核心目标在于建立入射电磁波、等离子体微观涨落与散射光谱之间的定量联系，从而为实验测量等离子体参数提供可靠的理论依据。

汤姆逊散射理论的物理起点是单电子对电磁波的散射过程。当频率远高于等离子体频率的电磁波入射到等离子体中时，每个电子在入射波电场的作用下发生受迫振荡，并作为偶极子向外辐射次级波。这一过程首先由经典电动力学给出定量的描述：单个电子的散射截面为汤姆逊截面，而散射光的频率相对于入射光发生了多普勒频移，其偏移量正比于电子速度在散射波矢方向上的投影。这一基本的频率-速度映射关系构成了后续所有推导的基石。

然而，等离子体是由大量相互关联的带电粒子构成的复杂多体系统，散射信号并非单个电子散射的简单叠加。理论推导的关键转折点在于认识到：如果电子在空间上完全均匀分布，各散射元之间的相位干涉将导致净散射为零；实际观测到的散射信号来源于电子密度的微观涨落。基于这一认识，理论引入了谱密度函数 $S(k,\omega)$，将散射功率谱与电子密度涨落的时空傅里叶谱直接关联起来。这一关联使得理论上可从散射信号反推等离子体内部的涨落特性，从而奠定了诊断的物理基础。

在建立了涨落与散射的宏观关联之后，理论推导进一步深入至微观动理学层面，以求解涨落的来源与幅度。通过采用 Vlasov 方程描述粒子的分布函数，并在线性化近似下耦合泊松方程，理论给出了密度涨落如何受粒子热运动和电荷屏蔽效应共同调制的完整描述。这一过程中，纵向介电函数 $\epsilon(k,\omega)$ 自然浮现，它集中体现了电子和离子对扰动的集体响应能力，也决定了涨落谱的共振结构。由此导出的形式因子表达式将散射谱显式地分解为电子贡献与离子屏蔽贡献两部分，清晰地揭示了散射信号所携带的等离子体信息。

散射参数 $\alpha = 1/(k\lambda_{De})$ 的引入标志着理论向实际应用的分化。当 $\alpha \ll 1$ 时，散射波长远小于德拜长度，入射波“看到”的是单个电子的无规运动，谱形直接反映电子速度分布，适用于电子温度与密度的测量。当 $\alpha \geq 1$ 时，散射波长达到或超过德拜长度，波与等离子体集体模耦合，散射谱中出现对应于电

子等离子体波和离子声波的共振峰，从而提供了测量离子温度、电离平衡以及等离子体波动幅度的途径。这一分类诊断能力正是汤姆逊散射成为等离子体物理核心工具的根本原因。

最后，理论的完备性还体现在对非理想效应的系统扩展上。通过保留相对论修正项，理论可适用于高温等离子体；通过在动理学方程中引入 BGK 碰撞项或 Fokker-Planck 项，理论可推广至碰撞占主导的稠密等离子体；通过将粒子轨道从直线改为螺旋线，理论可描述磁化等离子体中回旋运动对散射谱的调制。这些扩展使得汤姆逊散射理论能够覆盖从低密度高温聚变等离子体到高密度温稠密物质、从无磁场到强磁场等离子体的广阔参数空间，彰显了其作为等离子体诊断理论体系的完整性与普适性。

2.1 等离子体中的电磁散射

在汤姆逊散射的理论体系中，从单电子散射到可观测散射光谱的跨越，其核心环节在于建立起散射功率谱与等离子体密度涨落之间的宏观关联。这一关联的推导不仅体现了统计物理的基本思想，也是整个诊断理论从微观动力学走向宏观测量的逻辑桥梁。

理论推导的起点是考虑一个包含大量电子的散射体积。单个电子的散射电磁场是,

$$\vec{E}_s\left(\vec{r}_s,t\right)=-\frac{e}{cr_s g_{ret}}\hat{s}\times\left(\left(\hat{s}-\vec{\beta}_{ret}\right)\times\dot{\vec{\beta}}_{ret}\right). \tag{2.1}$$

其中, 因子 $g_{ret}=(1-\hat{s}\cdot\vec{\beta_{ret}})^3$, 电子在推迟时间, t_{ret} 时刻的归一化速度是,

$$\vec{\beta}_{ret}=\vec{v}\left(t_{ret}\right)/c. \tag{2.2}$$

推迟时间和探测时间, t 不同. 这种不同来自于电磁辐射从源点传播到探测点的传播时间. 这里, 观测点的位移是 $\vec{r_s}$, 电子的位移是 $\vec{r}$. 那么, 推迟时间可以这样计算,

$$t_{ret}=t-\left|\vec{r}_s-\vec{r}\right|/c\approx t-\left|\vec{r}_s\right|/c+\hat{s}\cdot\vec{r}/c. \tag{2.3}$$

其中,

$$\chi_e\left(k,\omega\right)=N_e\frac{e^2}{m_e}\frac{4\pi}{k^2}\int_{-\infty}^{\infty}dv\frac{1}{v-\omega/k}\frac{df_e\left(v\right)}{dv}. \tag{2.4}$$

在入射电磁波照射下，每个电子均独立地辐射次级波，观测点处的总散射场即为所有电子散射场的矢量叠加。因此总散射场可以用下面的公式计算,

$$\vec{E}_{total}\left(\vec{r}_s,t\right)=\int d\vec{r}\int d\vec{v}\ F_e\left(\vec{r},\vec{v},t\right)\vec{E}_s\left(\vec{r}_s,t\right), \tag{2.5}$$

$$\vec{E}_{total}\left(\vec{r}_s,\omega\right)=-\iiint_{-\infty}^{\infty}dt\ d\vec{r}\ d\vec{v}\ F_e\left(\vec{r},\vec{v},t\right)\frac{e}{c\left|\vec{r}_s\right|}\left(\hat{s}\times\left(\hat{s}\times\frac{d\vec{\beta}}{dt}\right)\right)exp\left(-i\omega t\right). \tag{2.6}$$

由于电子的运动来源于入射电场的驱动, 所以电子的运动速度是,

$$\frac{d\vec{\beta}}{dt}=-\frac{e\vec{E}_i}{m_ec}\cos\ \vec{k}_i\cdot\vec{r}-\omega_it\ . \tag{2.7}$$

其中, 下标为 i 的变量是入射电磁波的性质. 那么, 总散射场是,

$$\begin{aligned}\vec{E}_t\left(\vec{r}_s,\omega\right)=&\frac{e^2}{m_ec^2\left|\vec{r}_s\right|}\left(\hat{s}\times\left(\hat{s}\times\vec{E}_i\right)\right)\\&\times\iiint_{-\infty}^{\infty}dt\ d\vec{r}\ d\vec{v}\ F_e\left(\vec{r},\vec{v},t\right)\cos\left(\vec{k}_i\cdot\vec{r}-\omega_it\right)exp\left(-i\omega t\right).\end{aligned} \tag{2.8}$$

这里的积分历遍了完整的位置空间和速度空间. 其中 $F_e(r,v,t)$ 是 t 时刻等离子体中所有电子在相空间中的分布函数. 注意到 t 时刻是探测时间而不是辐射场发射时的推迟时间, t_{ret} 时刻, 因此分布函数的定义是,

$$F_e\left(\vec{r},\vec{v},t\right)=\int_{-\infty}^{\infty}dt_{ret}\sum_{j=1}^{N}\delta\left(\vec{r}-\vec{r}_j\left(t_{ret}\right)\right)\delta\left(\vec{v}-\vec{v}_j\left(t_{ret}\right)\right)\delta\left(t_{ret}-t+\left|\vec{r}_s\right|/c-\left(\hat{s}\cdot\vec{r}_j\right)/c\right). \tag{2.9}$$

由于各个电子的位置和速度不断变化，其散射场之间具有随机的相位差，总散射功率中不仅包含各电子独立贡献的强度之和，还包含了不同电子散射场之间

的干涉项。问题的关键在于如何系统地处理这种干涉效应，而这一问题的答案深刻地依赖于电子的空间分布特征。因此, 这一答案可以体现在下面的表达式中,

$$\vec{E}_{total}\left(\vec{r}_s,\omega\right)=\frac{e^2}{m_e c^2\left|\vec{r}_s\right|}\left(\hat{s}\times\left(\hat{s}\times\vec{E}_{i0}\right)\right)$$
$$\times\iint_{-\infty}^{\infty}dt_{ret}\ d\vec{r}\ n\left(\vec{r},t_{ret}\right)\cos\left(\vec{k}_0\cdot\vec{r}-\omega_0\left(t_{ret}+\frac{\left|\vec{r}_s\right|}{c}-\frac{\hat{s}}{c}\cdot\vec{r}\right)\right)exp\left(-i\omega\left(t_{ret}+\frac{\left|\vec{r}_s\right|}{c}-\frac{\hat{s}}{c}\cdot\vec{r}\right)\right). \tag{2.10}$$

若等离子体中的电子完全均匀地分布，则任意一对电子的散射场之间总存在另一个电子提供相反的相位，导致干涉项完全相消，宏观上观测不到任何净散射。然而, 实际的等离子体因热运动、静电相互作用及集体波动, 其密度在局部时刻偏离均匀值，这种偏离即密度涨落。正是这些涨落破坏了完美的相位相消，使得散射信号得以产生。这一物理洞见为理论推导指明了方向：散射信号是电子密度涨落的直接体现，而非平均密度的响应。基于这一认识，理论推导引入了一个关键的数学工具——电子密度涨落的时空傅里叶变换,

$$n\left(\vec{r},t\right)=\frac{1}{\left(2\pi\right)^4}\iint dkd\omega\ n_e\left(\vec{k},\omega\right)e^{i\vec{k}\cdot\vec{r}-i\omega t}. \tag{2.11}$$

将散射体积内的密度涨落分解为一系列具有确定波矢, k 和频率, ω 的傅里叶分量，每个分量对应等离子体中特定尺度与频率的涨落模式。代入了这个傅里叶变换后, 可以利用 δ 函数的性质, 将总散射场变为下面形式,

$$\vec{E}_{total}\left(\vec{r}_s,\omega_s\right)=\frac{1}{2}\frac{e^2}{m_e c^2 r_s}\left(\hat{s}\times\left(\hat{s}\times\vec{E}_i\right)\right)$$
$$\times\left(n_e\left(-\vec{k}_i-\frac{\hat{s}}{c}\left(\omega_i-\omega_s\right),\omega_i-\omega_s\right)+n_e\left(\vec{k}_i-\frac{\hat{s}}{c}\left(-\omega_i-\omega_s\right),-\omega_i-\omega_s\right)\right). \tag{2.12}$$

与此同时，散射实验中入射波与散射波之间的波矢差 $k=k_s-k_i$ 和频率差 $\omega=\omega_s-\omega_i$ 恰好决定了该实验所敏感的涨落模式。于是，散射过程在波矢-频率空间中表现为入射波与特定涨落模式之间的耦合，总散射场则成为所有涨落分量贡

献的叠加。我们只保留三波耦合的项, 并且考虑到电子密度分布是实数, 因此我们有下面的表达式,

$$\vec{E}_{total}\left(\vec{r}_s,\omega_s\right) = \frac{1}{2}\frac{e^2}{m_e c^2 r_s}\left(\hat{s}\times\left(\hat{s}\times\vec{E}_i\right)\right) n_e\left(\vec{k}_i-\frac{\hat{s}}{c}\left(\omega_s-\omega_i\right),\omega_s-\omega_i\right). \tag{2.13}$$

为了从理论上计算散射功率谱，需要对众多电子的随机运动进行统计平均。由于等离子体通常处于局部热力学平衡或准稳态，其涨落满足各态历经性，系综平均可等效为时间平均。在这一框架下，散射功率谱被严格地表达为密度涨落傅里叶分量模平方的系综平均值。由此，理论定义了一个核心物理量——谱密度函数，

$$S\left(\vec{k},\omega\right)=\frac{1}{n_{e0}}\left|n_e\left(\vec{k},\omega\right)\right|^2. \tag{2.14}$$

其中, n_{e0} 是等离子体的平均密度. 它本质上就是单位体积、单位频率间隔内密度涨落的功率谱密度。该函数完全决定了散射光谱的形状与绝对强度，而后者又直接由等离子体的动理学性质（分布函数、介电响应等）所决定。因此, 散射功率谱函数是,

$$P_s\left(\vec{k}_s,\omega_s\right)d\Omega d\omega_s=\frac{1}{2\pi}I_0 r_e^2 V n_{e0}\left|\hat{k}_s\times\left(\hat{k}_s\times\hat{E}_i\right)\right|^2 S\left(\vec{k}_s-\vec{k}_i,\omega_s-\omega_i\right)d\Omega d\omega_s. \tag{2.15}$$

其中, I_0 是入射光的光强, V 是入射光和等离子体发生相互作用的体积. 而 r_e 是经典电子半径,

$$r_e=\frac{1}{4\pi\epsilon_0}\frac{e^2}{m_e c^2}. \tag{2.16}$$

当然, 上述的推导基于了低温等离子体假设. 如果考虑高温等离子体中电子热运动造成的相对论效应, 那么应该增加相对论修正因子,

$$P_s\left(\vec{k}_s,\omega_s\right)d\Omega d\omega_s=\frac{1}{2\pi}I_0 r_e^2 V n_e\left(\frac{2\omega_s}{\omega_i}-1\right)\left|\hat{k}_s\times\left(\hat{k}_s\times\hat{E}_i\right)\right|^2 S\left(\vec{k}_s-\vec{k}_i,\omega_s-\omega_i\right)d\Omega d\omega_s. \tag{2.17}$$

这一推导过程的意义在于，它成功地将宏观可测的散射信号与微观的涨落谱联系为简单的正比关系。从实验角度看，测量散射光谱等价于测量等离子体的密度涨落谱；从理论角度看，计算散射光谱则归结为利用动理学方程求解涨落谱。正是这一宏观关联的建立，使得汤姆逊散射从一种简单的“照亮粒子”的物理现象，升华为一种能够诊断等离子体集体行为与微观动力学的系统性方法，为其后续对非集体与集体散射的分类讨论以及对温度、密度、波动幅度的定量测量奠定了坚实的理论基础。

2.2 等离子体的谱密度函数

在汤姆逊散射的理论推导中，谱密度函数 $S(k,\omega)$ 的计算是整个理论体系的数学核心。这一推导过程从等离子体的动理学描述出发，通过系统的线性化处理和傅里叶-拉普拉斯变换，最终将涨落谱与介电响应函数联系起来，其详细过程充分体现了等离子体物理中“集体效应”的本质。

推导的出发点是 Vlasov 方程，它精确描述了每个带电粒子在自洽电磁场中的运动。对于无磁场、无碰撞的等离子体，

$$\frac{\partial}{\partial t}\left(F_q\right)+\vec{v}\cdot\frac{\partial}{\partial \vec{r}}\left(F_q\right)+\frac{Q_q}{m_q}\vec{E}\cdot\frac{\partial}{\partial \vec{v}}\left(F_q\right)=0. \tag{2.18}$$

该方程与泊松方程,

$$\vec{\nabla}\cdot\vec{E}=4\pi\sum_q Q_q\int d\vec{v}\ F_q. \tag{2.19}$$

构成封闭方程组。注意这里的下标 q 应该历遍等离子体中所有的成分，包括电子和不同种类的正离子. 由于直接求解所有粒子的轨道在数学上不可行，理论采用标准的微扰展开：将分布函数 F_q 分解为系综平均部分 F_{0q} 和涨落部分 F_{1q}，并假定涨落幅度远小于平均值。在线性化近似下，涨落部分的演化方程保留了粒子沿未扰动轨道运动的对流项以及平均分布函数梯度与扰动电场的耦合项，而忽略了涨落之间的非线性相互作用,

$$\frac{\partial}{\partial t}\left(F_{0,q}\right)+\vec{v}\cdot\frac{\partial}{\partial \vec{r}}\left(F_{0,q}\right)=0, \tag{2.20}$$

$$\frac{\partial}{\partial t}\left(F_{1,q}\right)+\vec{v}\cdot\frac{\partial}{\partial \vec{r}}\left(F_{1,q}\right)+\frac{Q_q}{m_q}\vec{E}_1\cdot\frac{\partial}{\partial \vec{v}}\left(F_{0,q}\right)=0, \tag{2.21}$$

$$\vec{\nabla}\cdot\vec{E}_1 = 4\pi\sum_q Q_q\int d\vec{v}\ F_{1,q}. \tag{2.22}$$

这一线性化步骤的合理性在于散射实验通常采用低功率探针光，不会显著改变等离子体的平衡状态。

接下来采用傅里叶-拉普拉斯变换将偏微分方程转化为代数方程。由于散射实验测量的频率为实数，但初始值问题的处理要求复频率平面上的解析延拓，因此采用拉普拉斯变换并取衰减因子 $\gamma->+0$ 的极限，以确保因果性，

$$\begin{aligned}-F_{1,q}(k,v,0)-(i\omega+\gamma)F_{1,q}(k,\omega,v)+\vec{v}\cdot i\vec{k}F_{1,q}(k,\omega,v)\\ -\frac{Q_q}{m_q}\frac{4i\pi}{k}\rho_1(k,\omega)\frac{\partial}{\partial v_k}\left(F_{0,q}(r,t,v)\right)=0,\end{aligned} \tag{2.23}$$

$$\rho_1(k,\omega)=\sum_q Q_q\int d\vec{v}\ F_{1,q}(k,\omega,v). \tag{2.24}$$

经过变换后，扰动分布函数 $F_{1q}(k,\omega,v)$ 可显式地表示为两项之和：第一项，$F_{1q}(k,v,0)$，来源于初始时刻的密度涨落（粒子沿未扰动轨道自由运动），第二项，$F_{1q}(k,\omega,v)$，来源于扰动电场对平均分布函数的调制（即粒子的集体响应）。将扰动分布函数对速度积分，即可得到各粒子种类的密度涨落，

$$n_{1,q}(k,\omega)=\int dv\ \frac{F_{1,q}(k,v,0)}{\vec{v}\cdot i\vec{k}-i\omega}+\frac{Q_q}{m_q}\frac{4i\pi}{k}\rho_1(k,\omega)\int dv\ \frac{\frac{\partial}{\partial v_k}\left(F_{0,q}(r,t,v)\right)}{\vec{v}\cdot i\vec{k}-i\omega}. \tag{2.25}$$

多组分等离子体的处理方法和单组分的处理方法相同. 为了简化讨论流程，我们先讨论单组分的等离子体. 电子和离子的分布函数分别满足如下的方程，

$$\rho_1(k,\omega)=Z_i e n_{1,i}(k,\omega)-e n_{1,e}(k,\omega), \tag{2.26}$$

$$n_{1i}(k,\omega)\ =\ \int dv\ \frac{F_{1i}(k,v,0)}{\vec{v}\cdot i\vec{k}-i\omega}\ +\ N_{0i}\frac{Ze}{m_i}\frac{4i\pi}{k}\rho_1(k,\omega)\int dv\ \frac{\frac{\partial}{\partial v_k}\left(f_i(v)\right)}{\vec{v}\cdot i\vec{k}-i\omega}. \tag{2.27}$$

此时，泊松方程将电子和离子的密度涨落通过扰动电荷密度 $\rho_1(k,\omega)$ 耦合起来，

$$\rho_1(k,\omega)=Z e n_{1,i}(k,\omega)-e n_{1,e}(k,\omega). \tag{2.28}$$

将电子的密度涨落表达式代入泊松方程，消去离子密度涨落，经过代数运算后即可得到电子密度涨落的封闭表达式,

$$n_{1e}\left(k,\omega\right)=\frac{1+\chi_i\left(k,\omega\right)}{1+\chi_e\left(k,\omega\right)+\chi_i\left(k,\omega\right)}\int dv\ \frac{F_{1et}\left(k,v,0\right)}{\vec{v}\cdot i\vec{k}-i\omega} - \frac{Z\chi_e\left(k,\omega\right)}{1+\chi_e\left(k,\omega\right)+\chi_i\left(k,\omega\right)}\int dv\ \frac{F_{1it}\left(k,v,0\right)}{\vec{v}\cdot i\vec{k}-i\omega}. \quad (2.29)$$

在这一过程中，纵向介电函数 $\epsilon(k,\omega)=1+\chi_e(k,\omega)+\chi_i(k,\omega)$ 自然浮现，其中 χ_e 和 χ_i 分别为电子和离子的极化率，它们由速度空间积分,

$$\chi_e\left(k,\omega\right)=N_{0e}\frac{e^2}{m_e}\frac{4i\pi}{k}\int dv\ \frac{\frac{\partial}{\partial v_k}\left(f_e\left(v\right)\right)}{\vec{v}\cdot i\vec{k}-i\omega}, \quad (2.30)$$

$$\chi_i\left(k,\omega\right)=N_{0i}\frac{\left(Ze\right)^2}{m_i}\frac{4i\pi}{k}\int dv\ \frac{\frac{\partial}{\partial v_k}\left(f_i\left(v\right)\right)}{\vec{v}\cdot i\vec{k}-i\omega}. \quad (2.31)$$

定义。这个积分包含了重要的物理信息：当分母为零时，即波的相速度与粒子速度共振时，积分出现奇异性，这正是朗道阻尼和朗道增长的微观起源。

得到了电子密度涨落的傅里叶-拉普拉斯表达式后，谱密度函数的计算进入最后一步——系综平均。对于初始时刻无关联的均匀等离子体，不同粒子之间的初始相位平均为零，只有自相关项（即同一粒子贡献的项）和通过介电函数关联的集体项（即屏蔽云贡献的项）在热力学极限下保留下来, 谱密度函数最终取如下简洁形式：

$$S\left(\vec{k},\omega\right)=\frac{2\pi}{k}\left|1-\frac{\chi_e}{\epsilon}\right|^2 f_e\left(\frac{\omega}{k}\right)+\sum_j\frac{2\pi}{k}\frac{p_jZ_j^2}{Z}\left|\frac{\chi_e}{\epsilon}\right|^2 f_j\left(\frac{\omega}{k}\right). \quad (2.32)$$

这一表达式将谱密度函数明确地分解为两项：第一项对应“裸电子”及其电子屏蔽云贡献，当 $\alpha\ll1$ 时退化为非集体散射项；第二项对应离子的屏蔽云贡献，它是集体离子特征的来源。两项均以 $|\epsilon|^2$ 为共同分母，这意味着当介电函数取极小值时，散射谱将出现共振增强，对应于等离子体本征模式的激发。至此，谱密度函数完全由平衡分布函数和介电函数所决定，整个推导清晰地展现了微观粒子动力学如何通过统计平均和集体响应汇聚为宏观可测的散射光谱。

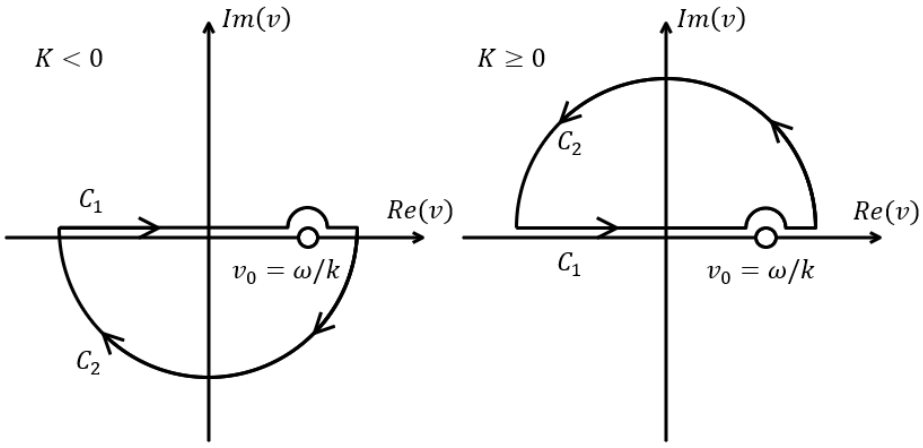


图 2.1: 围道积分的路径选择示意图. 当参数 $K<0$ 时，被积函数在上半平面无穷远处发散，故无穷远围道取半径无穷大的下半圆弧，此时围道包围一个奇点（图中标记）；当 $K\geq 0$ 时，函数在下半平面无穷远处发散，无穷远围道改为上半圆弧，围道内不含奇点。箭头表示积分方向.

2.3　谱分解法计算介电系数

在非平衡态等离子体的汤姆逊散射诊断中，电子速度分布函数（Electron Velocity Distribution Function, EVDF）$f_e(v)$ 通常偏离麦克斯韦分布且无法用少数参数解析描述。此时，电子极化率 $\chi_e(k,\omega)$ 的计算不能采用平衡态下的近似表达式，而必须直接处理其定义中的速度空间积分：

$$\chi_e\left(k,\omega\right)=N_e\frac{e^2}{m_e}\frac{4\pi}{k^2}\int_{-\infty}^{\infty}dv\frac{1}{v-\omega/k}\frac{df_e\left(v\right)}{dv}. \tag{2.33}$$

其中积分路径需按朗道围道取法绕过奇点 $v=\omega/k$。传统的数值方法是在速度空间对 $f_e(v)$ 及其导数离散采样后直接求和，对于需要频繁计算 χ_e 的迭代反演或神经网络训练而言，这种方法的计算负担往往难以接受。

为突破这一瓶颈，我们发展了一种基于傅里叶展开的快速计算方法。将任意 EVDF, $f_e(v)$ 表示为其傅里叶变换的形式：

$$f_e\left(v\right)=\frac{1}{2\pi}\int_{-\infty}^{\infty}dK\ F_e\left(K\right)e^{-iKv}. \tag{2.34}$$

其中 $F_e(K) = \int_{-\infty}^{\infty} dv f_e(v) e^{iKv}$ 为 $f_e(v)$ 的傅里叶变换。将这一表示代入 χ_e 的定义式，并交换积分次序，得到：

$$\chi_e(k,\omega) = N_e \frac{e^2}{m_e} \frac{4\pi}{k^2} \int_{-\infty}^{\infty} dv \, \frac{1}{v-\omega/k} \frac{d}{dv} \left(\frac{1}{2\pi} \int_{-\infty}^{\infty} dK \; F_e(K) \, e^{-iKv} \right). \quad (2.35)$$

对速度 v 的内层积分可解析完成。这一积分在复平面上可通过留数定理精确求解。根据 K 的符号，积分路径需在上半平面或下半平面闭合：当 K>0 时，指数因子 e^{-iKv} 在上半平面发散，积分须在下半平面闭合，而奇点 $v = \omega/k$ 位于实轴上，因此结果为 0；当 $K \leq 0$ 时，积分在上半平面闭合，围道包围奇点，贡献为 $2\pi i e^{-iK\omega/k}$。综合两种情况，得到简洁的表达式：

$$\chi_e(k,\omega) = N_e \frac{e^2}{m_e} \frac{4\pi}{k^2} \int_0^{\infty} dK F_e(K) \, K exp(-iK\omega/k). \quad (2.36)$$

该表达式蕴含了一个关键的物理事实：在非平衡态下，极化率 χ_e 完全由 EVDF 傅里叶变换 $F_e(K)$ 的非负频率分量所决定. $F_e(K)$ 代表 EVDF 在速度空间中波数为 K 的振荡分量，该表达式的积分核含因子 K，这意味着 EVDF 中速度变化越剧烈的成分（对应较大的 K）对 χ_e 的贡献被线性放大。这与散射光谱对 EVDF 高频成分异常敏感的病态特性在数学上同源——二者均源于被积函数中 $v - \omega/k$ 奇点与指数振荡因子的相互调制，但傅里叶方法将这种敏感性转化为一个可解析处理的正向问题，而非反演时的病态来源。

这一傅里叶展开方法的优势体现在多个层面。在计算效率上，由于 $F_e(K)$ 随 K 增大而迅速衰减，实际计算时仅需截取前 80 个低频分量即可将相对误差控制在约 1.5×10^{-4} 以内，所需采样点数约为直接积分的五千分之一 (见图 2.2)。在数值精度上，留数定理的解析处理完全规避了直接积分中奇点附近的数值发散问题，从根本上消除了因极点处理不当带来的数值不稳定性。在数据驱动建模方面，该方法天然适合于神经网络框架——傅里叶分量 $F_e(K)$ 恰好可作为神经网络的输出层，使得模型在学习从光谱到 EVDF 的映射时，能直接与快速正演计算对接，大幅缩短了训练数据的生成周期。同时，在频域中施加低通滤波等正则化约束也更为自然，为抑制反问题的病态性提供了便利的数学工具。

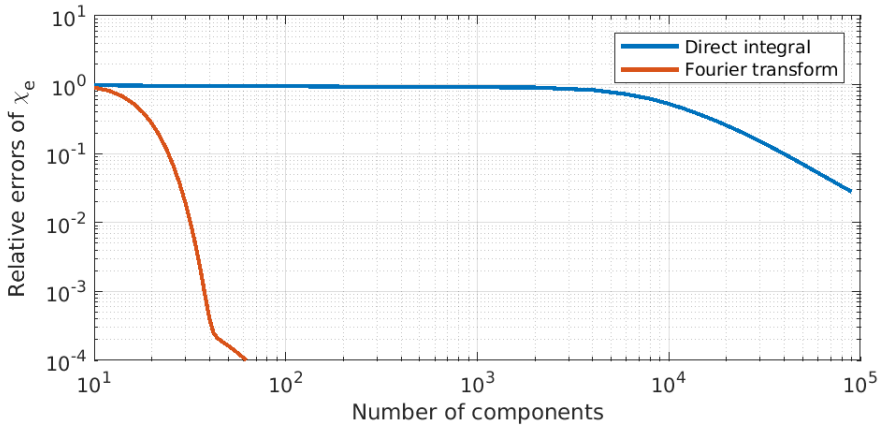


图 2.2: 对比了直接积分法与基于傅里叶变换的方法计算同一积分时的效率差异。横轴表示采样点数目：直接积分对应实空间采样点数，傅里叶方法对应傅里叶空间采样点数；纵轴表示计算误差。结果显示，在相同采样点数目下，基于傅里叶变换的方法通常能达到更低的误差，或只需更少采样点即可达到同等精度，从而体现出计算效率上的优势。

第三章　梯度下降法的反解方案

在等离子体汤姆逊散射诊断中，散射光谱 $S(\omega)$ 对应于电子速度分布函数（Electron Velocity Distribution Function, EVDF），$f_e(v)$ 沿散射波矢方向的一维投影。然而，在集体散射条件下，由于电荷屏蔽效应与朗道阻尼的调制作用，光谱与 EVDF 之间呈现复杂的非线性卷积关系，这为从实测光谱反演 EVDF 带来了本质性的困难。

在数学上，该问题属于第一类 Fredholm 积分方程的反问题，其显著特征是不适定性（ill-posedness）：解对测量噪声的高度敏感性导致直接反演结果发散，且解的非唯一性使得传统优化方法难以收敛到物理上有意义的解。因此，必须引入适当的正则化策略或先验物理约束以限定解空间。本研究系统比较了三种不同层次的 EVDF 重建方案，从简单的参数化模型到非参数化直接优化，再到融合物理信息的神经网络方法，逐步揭示该反演问题的本质困难并探索可行的解决路径。

3.1　基于参数化基函数的先验约束方法

3.1.1　多高斯叠加模型及其数学形式

我们首先考察了一种高度受限的参数化模型——多高斯叠加方案。其基本思路是将待求的 EVDF 表示为若干中心位置固定于零点、宽度呈等差数列递增的高斯函数的线性叠加：

$$f_e(v) = \sum_{i=i}^{N} a_i G_i(v), \tag{3.1}$$

$$G_i(v) = \frac{1}{\sqrt{2\pi}\sigma_i} exp\left(-\frac{v^2}{2\sigma_i^2}\right). \tag{3.2}$$

其中高斯宽度 σ_i 预先设定为从小到大的固定序列，仅各分量系数 a_i 作为可调参数参与优化。通过正向计算得到对应的 OTS 光谱后，以实测光谱与计算光谱之间的残差平方和作为损失函数：

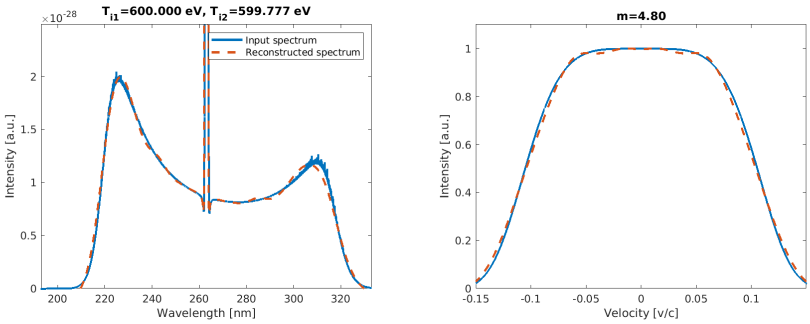


图 3.1: 超高斯 EVDF(m=4.8) 的多高斯叠加模型重建示意图. 左图为实际汤姆逊散射光谱与重建光谱的对比，二者高度吻合，验证了反演算法的准确性；右图为实际 EVDF 与重建 EVDF 的对比，重建分布能较好地还原超高斯轮廓及边缘衰减行为。整体结果表明，该方法可有效用于非麦克斯韦分布下的电子速度分布函数重建。

$$L\left(\vec{a}\right)=\int d\omega\ \left|S_{meas}\left(\omega\right)-S_{calc}\left(\omega,\vec{a}\right)\right|^{2}. \tag{3.3}$$

采用梯度下降法迭代优化系数向量 $\vec{a}$，其更新规则为:

$$\vec{a}_{t+1}=\vec{a}_{t}-\eta\vec{\nabla}_{a}L\left(\vec{a}_{t}\right). \tag{3.4}$$

其中 η 为学习率，梯度 $\nabla_{a}L$ 通过自动微分或数值差分计算。

3.1.2 测试结果与模型局限

我们以一组已知的超高斯 EVDF 为目标函数，生成了对应的 OTS 光谱作为测试基准。重建结果如图 3.1所示，在特定条件下能够获得较为合理的重建效果，相对误差约为 2%。然而，该方案存在三项根本性局限，严重制约了其普适性与发展价值。

第一，对称性约束。所有高斯分量的中心位置均固定于 $v=0$，导致叠加结果必然呈现左右对称形式。这从根本上排除了重建任意非对称 EVDF 的可能性。在等离子体物理中，电子速度分布函数的非对称性广泛存在于多种重要物理情境中：温度梯度驱动的非局域热流会产生冷电子回流（return current），表现为分布在低速区的非对称畸变；外加电场或激光有质动力则可能产生沿特定方向的电子漂移，使 EVDF 整体偏离对称形态；在双流不稳定性或受激散射过

程中，电子分布函数还可能呈现多峰结构。因此，中心对称假设严重限制了该方法在真实等离子体诊断中的应用价值。

第二，基函数不完备性问题。高斯函数族作为平方可积函数空间 $L^2(R)$ 中的一组特定函数族，并不构成完备基。这意味着并非所有物理上合理的 EVDF 都能分解为有限个高斯分量的叠加。对于具有重尾特征（如超高斯分布中 m<2 的情形）或双峰结构的 EVDF，高斯叠加模型的表达能力严重不足，其逼近误差可能远大于实验测量误差，导致系统性的重建偏差。

第三，展开非唯一性。若进一步放宽约束，允许各高斯分量的中心位置和宽度也作为可调参数，则会导致重建模型的非唯一性问题显著恶化。具体而言，若干个高斯分量的中心位置、宽度与幅值之间可以按特定规律协同变化而不改变叠加结果——例如，将一个分量变宽的同时减小其幅值并微调其位置，可被另一个分量的相应变化所补偿。这种参数冗余意味着损失函数在参数空间中存在大量平坦区域和虚假局部极小点，使梯度下降法难以稳定收敛到唯一的物理意义明确的解，甚至可能陷入由数值巧合而非物理规律决定的伪解。综合上述分析，多高斯叠加方案的发展价值较为有限。

3.2　基于非参数化的全局优化方法

3.2.1　方法描述与优化流程

为突破参数化模型的表达限制，我们考察了一种极端相反的方案——将 EVDF 在速度空间离散采样点上的函数值直接作为可调参数进行优化。具体而言，我们在速度轴上选取 N 个离散采样点 $v_1, v_2, ..., v_N$，将对应的函数值 $f_e(v_i)$ 全部作为独立的优化变量，总参数数量可达数百至上千。损失函数仍定义为实测光谱与计算光谱之间的残差平方和，梯度下降法的迭代格式为：

$$f_{t+1}\left(v_i\right) = f_t\left(v_i\right) - \eta \frac{\partial L}{\partial f\left(v_i\right)}. \tag{3.5}$$

3.2.2　优化结果与病态性分析

测试结果表明，该方案重建的 EVDF 几乎被高频噪声所主导，振荡剧烈，完全丧失物理意义。这一现象源于 OTS 反演问题的本质病态性——通过推导可证明，EVDF 的高频傅里叶分量对散射光谱的影响远大于低频分量。

具体而言，在集体散射条件下，散射光谱对 EVDF 各傅里叶分量的响应强度与波矢 k 和电子速度 v 的耦合方式密切相关。高频分量对应于 EVDF 中的精细结构，其产生的光谱调制幅度远大于低频分量。在梯度下降过程中，损失函数对各参数 $f(v_i)$ 的偏导数 $\partial L/\partial f(v_i)$ 反映的是该采样点对光谱的局部灵敏度。对于病态反问题，高频分量对应的偏导数值极大，这使得梯度下降法在迭代过程中优先调整高频分量。然而，现实中高频分量的成分极小，意味着这些方向的真实信号微不足道，而算法却将大量更新步长分配给了它们。由于主导梯度方向与实际解的主要成分不符，迭代结果会偏离真实解，收敛到包含大量无效高频噪声的错误解上。简言之，梯度方向被虚假的高频偏导误导，导致算法过度拟合无意义的扰动，而非真实的低频结构。

更为严重的是，这种非参数化优化完全不包含对解空间的先验约束，导致重建结果普遍违背基本物理规律。在速度量值方面，当 $|v| > c$ 时，物理上合理的 EVDF 应严格为零，但数值优化结果中这些区域却出现了大量有限值。在概率密度方面，由于损失函数仅依赖于光谱的平方残差，不涉及对 EVDF 非负性的约束，优化过程中 $f_e(v)$ 频繁出现负值——这在物理上毫无意义，因为分布函数代表概率密度，必须满足 $f_e(v) \geq 0$。

3.2.3 正则化策略与工程困难

上述问题可以通过引入适当的正则化项加以缓解。例如，可在损失函数中加入正则化项以抑制高频振荡，或加入非负约束采用投影梯度下降法。然而，正则化参数的选取本身即是一个需要仔细权衡的优化问题——过强的正则化会使解过度平滑而损失物理细节，过弱的正则化则无法有效抑制噪声放大。此外，物理约束（如归一化条件 $\int f(v)dv = 1$、有限速度支撑等）与梯度下降算法的逻辑并不天然兼容。虽然可通过拉格朗日乘子法或变量变换将约束融入优化框架，但此类部署显著增加了算法的复杂性与工程实现难度，且对于不同物理条件需重新设计约束形式，缺乏通用性。

3.3 基于物理信息神经网络的求解方案

3.3.1 物理信息神经网络的基本原理

物理信息神经网络（Physics-Informed Neural Networks, PINN）是近年来发展起来的一种求解偏微分方程及反问题的新型计算范式。与传统神经网络依

赖大规模标注数据不同，PINN 的核心思想是将物理规律——通常以偏微分方程、边界条件或积分约束的形式——直接嵌入神经网络的损失函数中。通过自动微分技术，网络输出对输入变量的各阶导数可精确计算，从而使物理残差项成为可微分的优化目标。

PINN 在处理反问题方面展现出独特优势。传统方法通常需要大量模拟数据作为训练集，属于数据驱动型（data-driven）方法，其泛化能力受限于训练样本的覆盖范围。而 PINN 由于保有物理信息，理论上可以在完全没有训练数据的条件下进行求解——唯一需要的是物理方程本身及相应的定解条件。这使得 PINN 特别适用于实验数据稀缺、物理过程复杂而先验知识较为明确的场景。

3.3.2　基于 PINN 的 EVDF 生成器设计

在本研究中，我们将 PINN 作为一种具有物理约束的 EVDF 生成器。网络架构如图3.3所示.

输入为一个固定的低温高斯函数 $f_{e,0}(v)$，代表先验的低速电子群体；输出为待求的 EVDF，$f_e(v)$，每个网络单元对应于速度采样点 v_i 上的分布函数值 $f_e(v_i)$。

网络主体采用五层一维卷积神经网络（1D-CNN）。经过系统的超参数扫描与稳定性测试，该构型在所有候选设计中表现出最优的收敛稳定性与重建精度。我们对该网络架构的合理性提出如下的唯像解释：每一层隐藏层可视为对 EVDF 的一次“滤波”操作，记第 j 层的输出为 $f_{e,j}(v)$。初始输入 $f_{e,0}(v)$ 是一个宽度很窄的高斯函数，其概率质量集中在低速区域，对应于物理上处于温度极低状态的电子群体。卷积操作以可学习的核函数在速度维度上滑动，相当于在相邻速度格点之间进行信息混合与扩散。若 $f_{e,j-1}(v)$ 是一个低温 EVDF，则在物理上合理的卷积核作用下，$f_{e,j}(v)$ 不可能突变为包含大量超高速电子的高温 EVDF——从 $f_{e,j-1}(v)$ 到 $f_{e,j}(v)$ 的演化对应于电子速度空间的逐步“升温”或“降温”过程，这种渐进性约束天然地抑制了重建结果中非物理的高能尾部涨落。

此外，速度空间中的卷积运算对应到傅里叶空间中为乘积操作。通过限制卷积核的空间窗口大小，我们实质上施加了一个高频滤波器——窗口越小，允许通过的最高频率越低。这等价于对 EVDF 施加了平滑性先验，从根本上抑制了非参数化方法中出现的高频噪声放大问题。同时，网络输出端采用 ReLU 激

活函数 $\sigma(x) = max\ (0, x)$ 确保 $f_e(v) \geq 0$ 严格成立。

3.3.3 性能评估与局限性

我们针对平衡态与非平衡态 EVDF 分别开展了重建测试。结果表明，对于麦克斯韦分布及其他平滑的平衡态分布，该方案能够取得较为满意的重建效果，如图 3.4所示。然而，该方法仍存在若干值得关注的局限性。

第一，重建结果具有一定程度的随机性。即便输入相同的高斯先验、相同的目标光谱和相同的网络初始化种子，多次运行得到的结果可能呈现出差异（见图 3.5）。进一步分析表明，这种随机性主要源于 OTS 诊断有限光谱窗口导致的解的非唯一性——在某些情况下，两个在物理上差异显著的 EVDF，其在有限频率窗口内对应的散射光谱几乎完全重合，损失函数无法区分这两种解。扩大光谱窗口可以部分缓解该问题，但窗口增大后损失函数的全局凸性减弱，梯度下降迭代更易陷入局部极小值，收敛到全局最优解的概率随之降低。

第二，对复杂 EVDF 的重建能力受限。当目标 EVDF 呈现多峰结构或剧烈非对称性时，成功收敛的概率显著下降。这可能是因为网络架构中隐含的“渐进扩散”先验对复杂分布的表达能力有限，无法覆盖所有可能的非平衡态形态。

第三，计算成本较高。PINN 方法需要反复求解正向模型以评估损失函数，而每一次评估涉及完整的卷积网络前向传播与光谱卷积计算。与经典优化方法相比，其计算时间增加了数十倍至数百倍不等，这对于需要快速迭代的实验数据分析构成了显著的效率瓶颈。然而，考虑到该方法在处理极端非平衡态方面的潜在价值，以及在训练完成后可极速部署于新数据的优势，这一计算代价在特定应用场景中仍可接受。

3.4 小结与展望

综上所述，本研究系统考察了三种不同层级的 EVDF 重建方案，揭示了 OTS 反演问题在不同约束条件下的本质特征。多高斯参数化方案实现简单但表达受限，非参数化直接优化方案通用性强但严重受制于病态性，而基于 PINN 的方案在物理约束融入方面展现出独特潜力，但仍需在计算效率和解的唯一性方面进一步改进。未来工作可考虑将多种正则化策略与 PINN 框架融合，发展混合先验驱动的重建算法，以在保持灵活性的同时有效抑制病态性，满足 ICF 实验中非平衡等离子体诊断的实际需求。

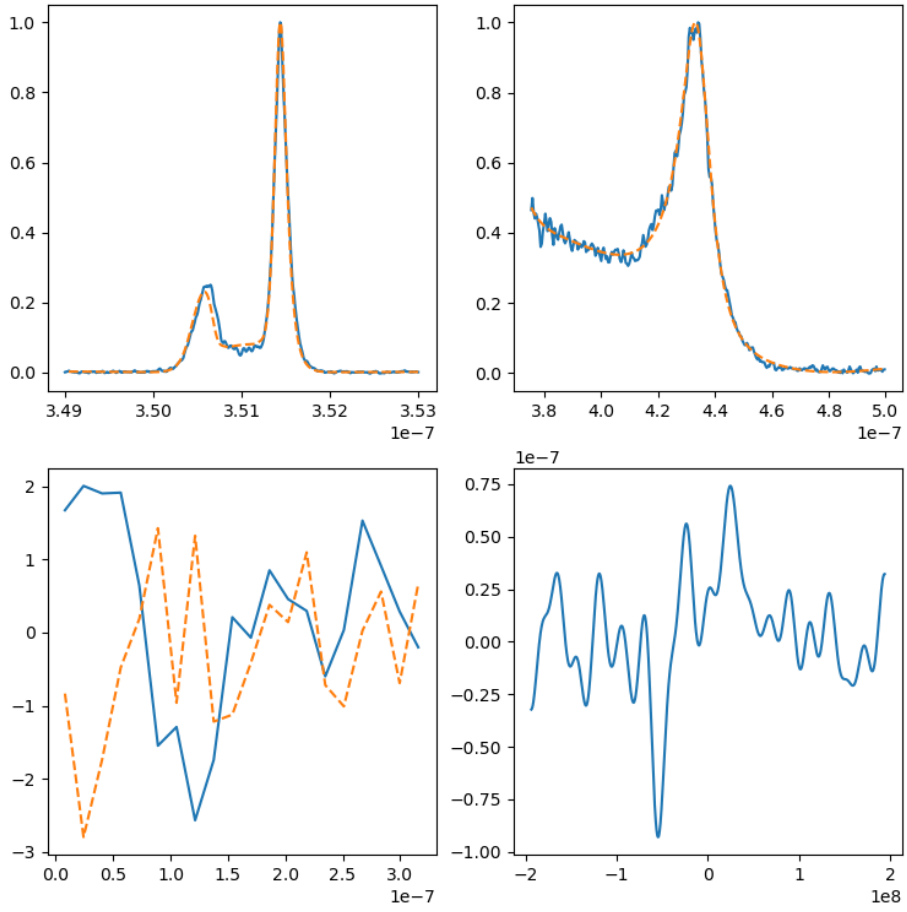


图 3.2: 非参数化的全局直接重建示意图. (a) 测量的汤姆逊散射离子光谱与重建离子光谱的对比，两者吻合良好；(b) 测量的电子光谱与重建电子光谱的对比，同样高度一致；(c) EVDF 在采样点上的傅里叶变换实部与虚部，作为优化过程中的中间量；(d) 最终重建得到的 EVDF。优化参数为 EVDF 在各采样点上的取值，通过对散射光谱的迭代拟合获得。

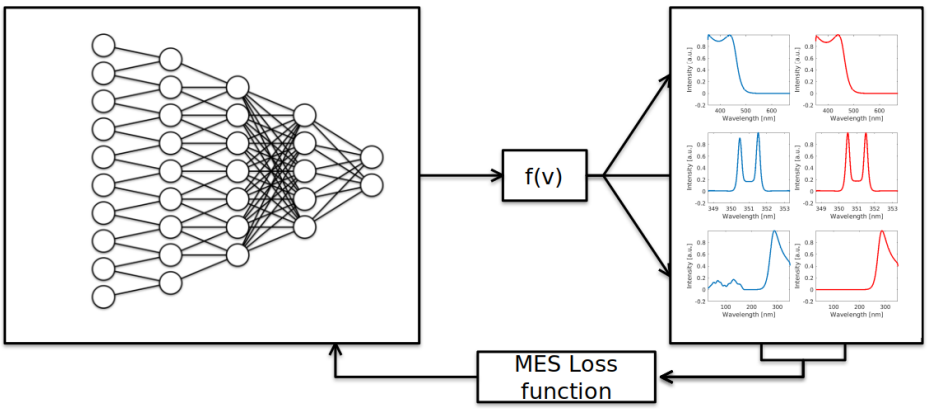


图 3.3: 基于 PINN 从汤姆逊散射光谱（OTS）重建等离子体电子速度分布函数（EVDF）的流程图。首先，将待求的 EVDF 参数化，作为物理信息神经网络（PINN）的输出。随后，将预测的 EVDF 代入 OTS 正向物理模型，模拟计算理论散射光谱。将理论光谱与实际测量 OTS 之间的残差作为损失函数。通过反向传播更新网络参数，迭代优化使损失函数最小化。最终，当预测光谱与实验 OTS 足够吻合时，神经网络输出的 EVDF 即为重建结果。该流程将正向物理模型嵌入网络训练，无需显式反演，可有效利用先验物理约束，实现从 OTS 到 EVDF 的稳健重建。

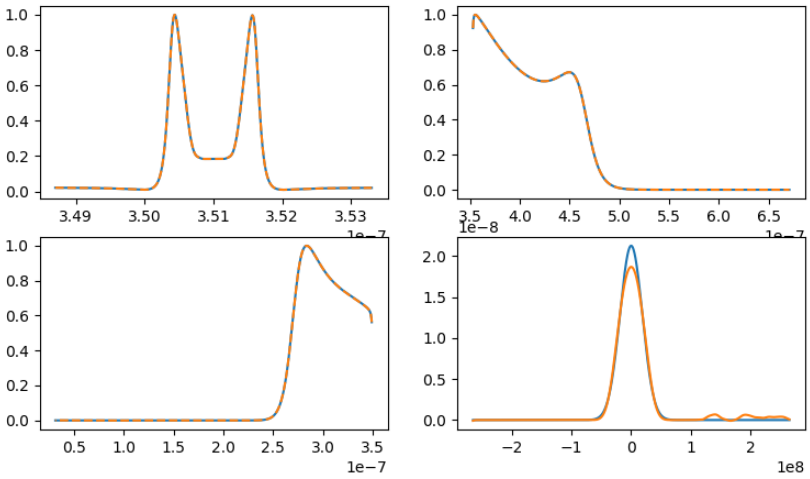


图 3.4: 基于 PINN 的电子速度分布函数（EVDF）重建结果。(a) 测量的汤姆逊散射离子光谱（实线）与 PINN 重建的离子光谱（虚线）对比，两者吻合良好；(b) 测量的红端电子光谱（实线）与重建电子光谱（虚线）对比；(c) 测量的蓝端电子光谱（实线）与重建电子光谱（虚线）对比，可见重建光谱在两端均能重现测量特征；(d) 真实 EVDF（蓝线）与 PINN 重建 EVDF（橙线）的对比，重建分布与真实分布基本一致，验证了 PINN 方法从散射光谱反演 EVDF 的有效性。

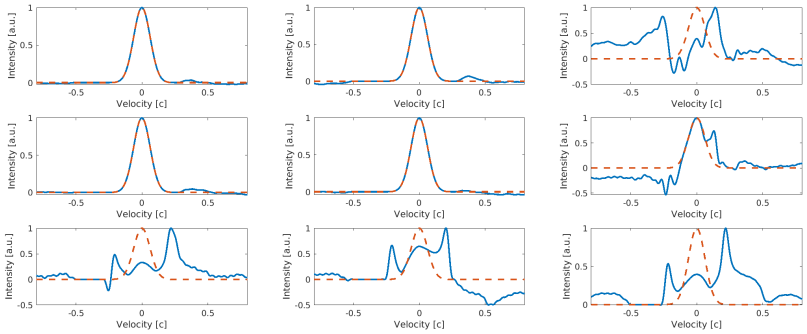


图 3.5: 使用 PINN 对同一 EVDF 进行的 9 次随机重建结果。蓝线为重建 EVDF，红色虚线为设定的目标 EVDF。9 次中 5 次重建明显偏离目标（失败），其余 4 次吻合较好，说明重建结果对随机初始化敏感，稳定性不足。

第四章　数据驱动的反解方案

如前文所述，在计算 χ_e 时, EVDF 以被微分的形式出现在被积函数中，且分母存在奇点（需通过围道积分处理），这使得从散射光谱反推 EVDF 成为一个典型的病态反问题。其病态性表现在两个方面：其一，解的不唯一性——不同的 EVDF 可能产生在观测窗口内难以区分的散射光谱；其二，解对测量噪声的高度敏感性——EVDF 的高频分量对光谱的贡献远小于低频分量，导致微小的测量误差即可在反演结果中放大为剧烈的非物理振荡。这两点是使用梯度下降法进行反解时, 遇到困难的根本原因.

针对这一挑战,我们发展了基于深度神经网络(Deep Neural Network, DNN)的反演方案。其核心思路是：通过大规模、多样化的训练数据集，让神经网络学习从散射光谱到 EVDF 的逆映射关系，从而绕开传统迭代优化方法在病态反问题中面临的困难。

4.1　数据集的构建策略

训练数据集的构建是神经网络方法成败的关键。我们采用的生成策略如下:

每个 EVDF 由 3 个随机生成的高斯函数叠加构成，每个高斯分量的宽度、幅度和中心位置分别在预设范围内均匀采样（宽度 0.01c 至 0.05c，幅度 0.2 至 2.5，中心位置 -0.06c 至 0.06c)。叠加后进行归一化处理。训练集包含 5000 个样本，测试集包含 100 个样本。

离子组分设定为 CH 等离子体，电子密度在 0.8×10^{26} 至 $2.0\times10^{26}cm^{-3}$ 范围内随机选取，离子温度在 80 eV 至 200 eV 范围内随机选取。离子速度分布假定始终保持麦克斯韦分布——这一假设的合理性在于离子质量远大于电子，激光驱动使其偏离平衡的程度可忽略不计。探针光波长和散射几何固定。基于这些参数，利用前述汤姆逊散射理论正向计算每个 EVDF 对应的散射光谱。

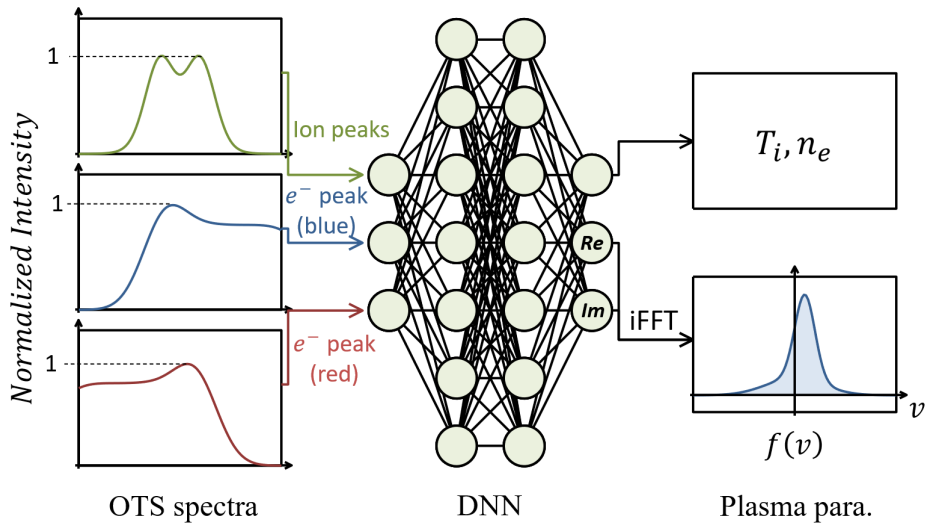


图 4.1: 基于深度神经网络（DNN）从汤姆逊散射光谱（OTS）重建等离子体电子速度分布函数（EVDF）的流程图。DNN 的输入分别为 OTS 的电子散射谱和离子散射谱。网络结构包含两层全连接隐藏层，用于提取谱线中的特征信息。输出端分为两部分：一是 EVDF 的傅里叶变换的实部与虚部，用于后续反演得到 EVDF；二是等离子体的离子温度与密度参数。该结果表明，所设计的 DNN 能够直接由散射光谱映射至 EVDF 的频域表示及关键等离子体参数，避免了传统迭代反演的高计算成本。

4.2 基于 DNN 的反演方案设计

4.2.1 网络架构和训练策略

如图 4.1所示，神经网络的输入为 1224 维向量，由三个归一化的光谱段拼接而成：离子特征谱（349–353 nm，579 个采样点）、红移电子特征谱（375–500 nm，304 个采样点）和蓝移电子特征谱（200–340 nm，341 个采样点）。每个谱段独立归一化至最大值为 1，这一处理至关重要——电子特征谱的强度通常比离子特征谱弱约两个量级，若不进行分段归一化，电子特征谱的信号将在训练中被离子特征谱完全淹没。

网络结构包含一个 1224 维的输入层、两个各 5000 维的全连接隐藏层（采用 Leaky ReLU 激活函数），以及一个 162 维的输出层（无非线性激活函数）。输出层的前 160 维表示 EVDF 傅里叶变换的实部和虚部（各 80 维），经逆傅里叶变换后得到速度范围 $-0.8c$ 至 $0.8c$ 上的 EVDF；剩余 2 维分别输出离子温

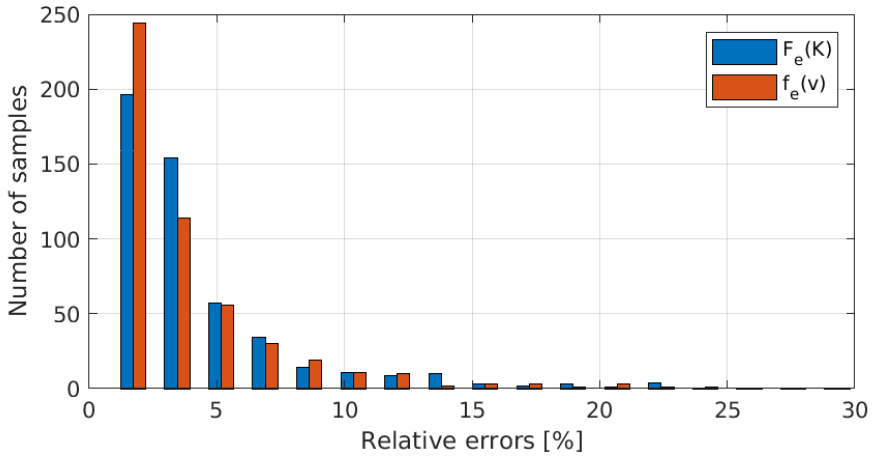


图 4.2: 柱状图比较了两种 DNN 输出层设计下，模型在测试集上的重建误差分布。蓝色柱体表示输出层为 EVDF 的傅里叶变换（$F_e(K)$），红色柱体表示输出层直接为 EVDF（$f_e(v)$）。横坐标为重建 EVDF 的相对误差。结果显示，两种设计下的误差分布无明显区别，表明输出层采用傅里叶变换形式不会显著影响重建精度。

度和等离子体密度.

选择傅里叶变换而非 EVDF 本身作为输出量，基于以下考虑：傅里叶变换使数据集的构建和部署更加灵活，且未来可依据傅里叶空间中的 OTS 理论在损失函数中设置频域权重。测试表明，两种输出方式的重建相对误差无显著差异 (如图 4.2所示)。

损失函数定义为训练集中预测 EVDF 与真实 EVDF 之间的均方误差(Mean Squared Error, MSE)。采用 Adam 优化器，训练分为四个阶段：前 3000 轮学习率为 1×10^{-4}，随后 6000 轮降至 1×10^{-5}，之后 10000 轮降至 1×10^{-6}，最后 100000 轮降至 1×10^{-7}。模型在 CPU 节点（2 x Intel Xeon Scalable Cascade Lake 6248，2.5 GHz，20 核）上训练，耗时约 10 小时完成。训练过程中的损失下降曲线见补充材料图 4.3。

4.2.2　模型架构对性能的影响

我们系统比较了不同神经网络架构的性能。图 4.4展示了测试结果。令人意外的是，最常用的卷积神经网络（CNN）在该问题上的表现远逊于深度神经网络（DNN）。这源于 CNN 架构固有的平移不变性和旋转不变性假设——OTS 光谱不具备这些性质，因为光谱中的特征峰位置携带着关键的物理信息（如多

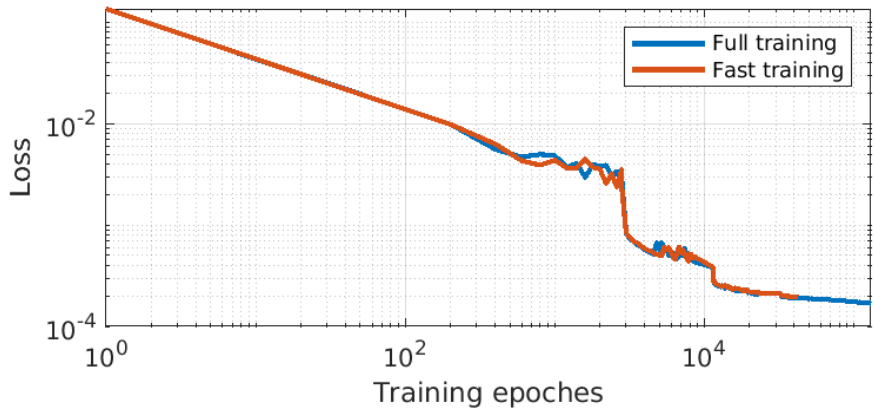


图 4.3: 不同训练模式下 DNN 训练误差随训练轮次的变化。蓝线为完整模式，训练分为四个阶段：前 3000 轮学习率为 1×10^{-4}，随后 6000 轮降至 1×10^{-5}，之后 10000 轮降至 1×10^{-6}，最后 100000 轮降至 1×10^{-7}。红线为快速模式，仅将最后阶段训练轮数减少为 10000 轮，其余阶段与完整模式相同。结果显示，快速模式与完整模式的最终训练误差差别不大。

普勒频移），而非仅仅是局部模式。在 DNN 的深度方面，我们发现增加隐藏层数并未带来性能提升。当隐藏层超过 8 层时，性能反而随深度增加而下降。虽然普遍认为更深层次的网络能增强泛化能力，但我们的测试表明，两层隐藏层的 DNN 已在 EVDF 重建中达到足够好的泛化效果，而更多层会因梯度消失问题导致性能显著下降。因此，最终模型采用两层隐藏层的设计。

4.2.3 隐藏层节点数的影响

在确定两层隐藏层的架构后，我们进一步考察了各层节点数对性能的影响。如图 4.5所示，在保持总参数量恒定的条件下，分别扫描两个隐藏层的节点数（从 10 个开始递增）。我们观察到一种阈值行为：当节点数低于某一阈值时，性能急剧恶化；一旦超过阈值，进一步增加节点数带来的提升十分有限。在我们的测试中，该阈值约为 30 个节点。我们将此阈值归因于光谱或速度分布函数中独立变量的数目。基于此，最终部署的模型将两个隐藏层设置为相同的节点数。

4.2.4 模型规模与性能的标度律

基于不同规模神经网络的统计测试结果（图 4.4），我们给出了一个经验公式，用于估算给定参数量 NN 下可获得的最优性能：

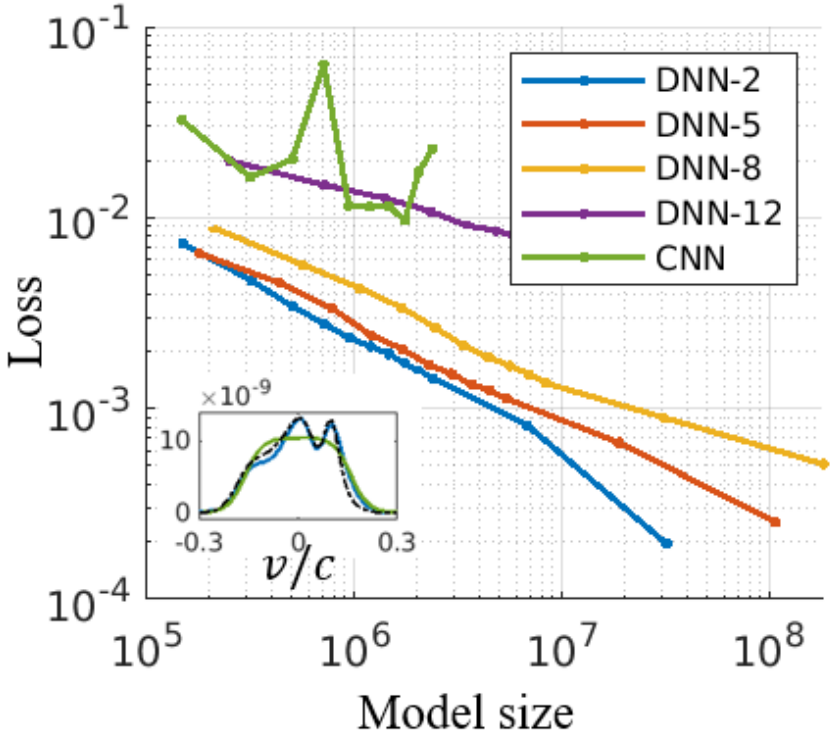


图 4.4: 不同神经网络训练后的损失值对比，包括 CNN 以及隐藏层数为 2、5、8、12 的 DNN（分别标记为 DNN-2、DNN-5、DNN-8、DNN-12）。插图展示了使用 DNN-2 与 CNN 重建的 EVDFs（电子速度分布函数）的比较结果。

$$L = \frac{0.3678}{N^{0.2685}}. \tag{4.1}$$

其中 L 为训练集上的平均损失。该标度律表明，通过简单地增加模型参数量即可持续提升重建质量——这一现象受益于现代神经网络优异的过参数化特性。过参数化是指网络参数量远超训练样本数的设计选择，它与传统统计学中“参数越多越易过拟合”的经典认知形成了鲜明的对比。然而，近年的深度学习的理论和实验研究均表明，在过参数化条件下，随机梯度下降的优化过程天然地具有隐式正则化效应，能够自动选择一类具有良好泛化能力的“简单”解。这种机制可以从几个层面理解：在优化轨迹上，梯度下降法倾向于优先沿着损失函数地形中曲率较小的方向更新，从而自动规避剧烈振荡的高频分量；从函数逼

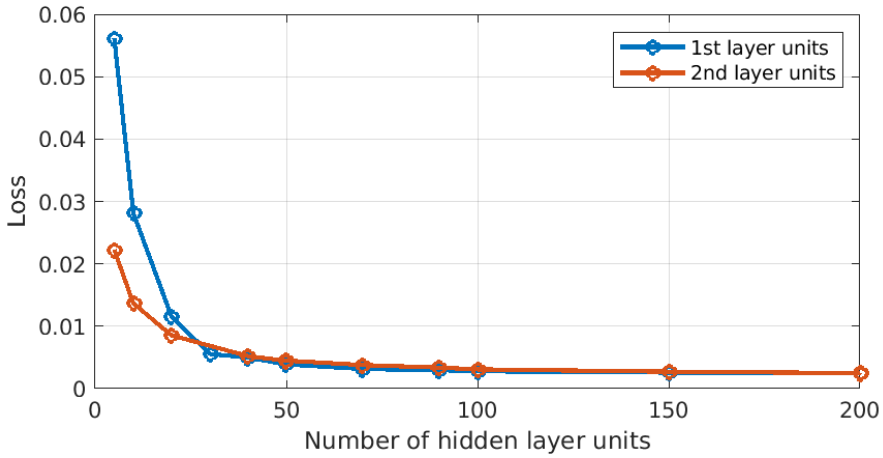


图 4.5: 不同隐层单元数配置下双层 DNN 的性能对比。横轴为第一层单元数，纵轴为第二层单元数，颜色表示模型性能。所有网络总参数数固定为 10^6，展示了在相同参数预算下，隐层分配对性能的影响。

近的角度看，过参数化网络具有更强的表示能力，能够在高维空间中更精细地拟合训练样本之间的内在结构，而不是简单地“记住”样本点；从泛化性能的角度看，双下降曲线的实验观测证实了当参数量增加到远超过临界值时，测试误差不仅不上升反而再次下降，这与过参数化使网络从“插值”状态进入“良性过拟合”状态密切相关。对于我们的 OTS 反演任务，过参数化使得网络能够在大量合成数据上充分提取谱-分布映射的统计特征，从而在测试集及部分分布外数据上均展现出稳定且高质量的重建表现。

4.3 数据库的影响与误差预测

4.3.1 重建误差与最短距离的关系

神经网络的泛化能力本质上依赖于训练集对目标函数空间的覆盖程度。我们通过大量实验发现，以下公式可作为 EVDF，$f_e(v)$ 重建误差 ϵ_{pred} 的有效预测：

$$\epsilon_{pred} = min_i \left(\frac{\sqrt{\int dv |f_e(v) - f_{e,i}(v)|^2}}{\int dv \, |f_e(v)|} \right). \tag{4.2}$$

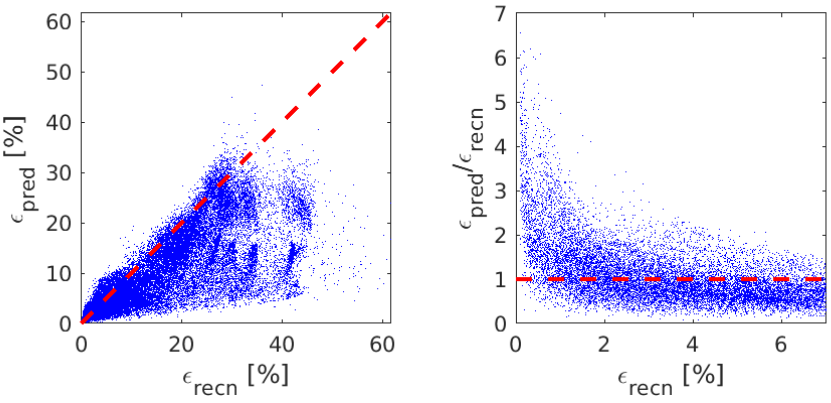


图 4.6: 重建 EVDF 的预测误差与实际误差的关系 (a) 横轴为重建 EVDF 的实际误差，纵轴为通过本文公式计算的预测误差。每个蓝点代表一个测试 EVDF；红色虚线为斜率为 1 的参考线，线上的样本表示预测误差等于实际误差。(b) 横轴为重建 EVDF 的实际误差，纵轴为预测误差与实际误差的比值；红色虚线同样表示预测误差等于实际误差。总体而言，若蓝点紧密围绕参考线或比值接近 1，则说明该误差预测公式能准确估计重建 EVDF 的误差；偏离程度则反映公式预测偏差的大小。

其中 $min\ i$ 遍历训练集中所有 EVDF，$f_{e,i}(v)$。该公式计算的是测试 EVDF 与训练集中最近邻 EVDF 之间的距离，表明重建误差直接取决于测试 EVDF 与训练集的相似程度。

图 4.6对比了预测误差与实际误差。当实际重建误差超过 4% 时，预测误差近似为实际误差的下界；当实际误差小于 4% 时，实际误差往往小于预测误差。这一现象揭示了神经网络在高维空间中函数拟合的本质行为：训练集作为样本点覆盖了参数空间的一部分。当测试 EVDF 与训练集的差异较小时，它落在训练集覆盖的参数空间内，训练集中可能有多个 EVDF 从不同方向逼近测试 EVDF，模型通过组合这些 EVDF 的特征可产生优于任何单个训练样本的重建结果。当差异较大时，测试 EVDF 位于覆盖空间之外，邻近的训练样本数量有限且特征相似，重建质量几乎不可能优于训练集中最接近的样本。

4.4　不同测试集的泛化误差

为确保模型具有足够高的泛化能力，我们采用多种策略生成测试集并测量泛化误差。

4.4.1 五高斯叠加测试集

如图4.7中的第一行所示, 第一类测试集由 5 个随机高斯函数叠加生成，参数范围与训练集相同。该测试集与训练集（3 个高斯叠加）的生成策略相似但分量数不同，用于检验模型对同一类分布中不同复杂度的泛化能力。图 S8 展示了该测试集上的重建误差分布。结果表明，模型对该类 EVDF 的重建误差中位数约为 2% 至 3%，与训练集上的表现相当，说明模型成功学习了高斯叠加这一类分布的基本特征，而非简单地记忆训练样本。

4.4.2 随机超高斯测试集

如图4.7中的第二行所示, 第二类测试集由随机超高斯函数生成，其形式为,

$$f_e(v) = Aexp\left(-\left(|m|/w\right)^m\right). \tag{4.3}$$

其中超高斯指数 m、宽度 w 和中心位置在合理范围内随机选取。这类分布完全不同于训练集中高斯叠加的生成方式，用于检验模型对全新分布类型的泛化能力。图 S8 显示，重建误差随超高斯指数 m 的变化呈现一定规律：当 m 接近 2（即接近高斯分布）时误差最小；随着 m 偏离 2，误差逐渐增大但仍保持在可接受范围内。这验证了模型能够将训练中获得的知识迁移至未见过的分布类型。

4.4.3 混合叠加测试集

如图4.7中的第三行所示, 第三类测试集由随机超高斯函数与 5 个随机高斯函数叠加生成。这类分布兼具超高斯的重尾特征和高斯叠加的多峰结构，用于检验模型对更复杂、更具挑战性的 EVDF 的重建能力。图 S8 表明，混合分布的重建误差略高于前两类测试集，但仍在 5% 以内，证实了模型对复杂 EVDF 具有足够的泛化能力。

4.5 数据库规模与生成策略对重建误差的影响

提升泛化误差的核心思路是增加目标区域的采样点密度。这可通过两种途径实现：一是增加随机样本的数量，二是改变训练样本的生成策略使其更集中于目标区域。两种途径各有优劣。由于 EVDF 分布在高维空间中（80 维，对应 EVDF 上的 80 个采样点），单纯增加样本数量对密度提升的效果有限。另一种

方式是限制随机 EVDF 的类型以缩小训练集覆盖的参数范围，但这将以牺牲泛化能力为代价。

图 4.8展示了训练集规模与泛化误差的关系。对于给定的生成策略，增加训练集规模确实能降低泛化误差，但收益随规模增大而递减——这符合高维空间中采样密度随样本数增长的规律（$N^{-1/d}$，其中 d 为维度）。当训练集规模从 500 增加到 5000 时，泛化误差显著下降；但从 5000 继续增加时，改善幅度趋于平缓。这表明在当前 80 维的参数空间中，5000 个训练样本已能提供较好的覆盖，进一步增加样本的边际收益有限。

图 4.9进一步比较了不同生成策略下训练的模型在各自留出测试集和随机超高斯测试集上的表现。结果显示，训练集的生成策略对模型在同类分布上的表现影响较小，但对跨类型泛化能力有显著影响。采用更多样化的生成策略（如同时包含高斯叠加和超高斯分布）训练的模型，在随机超高斯测试集上的表现优于仅使用单一策略训练的模型。这一发现对未来训练集的构建具有指导意义。

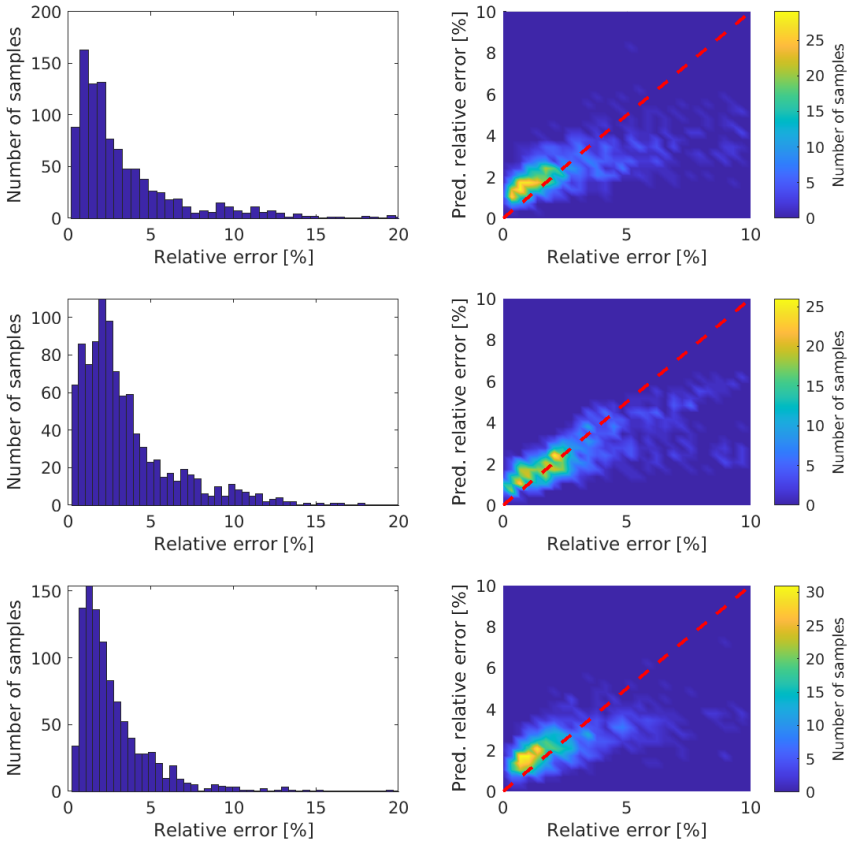


图 4.7: 展示了不同策略生成 EVDF 时的重建相对误差。策略包括：5 个随机高斯函数、随机超高斯函数、以及随机超高斯函数与 5 个随机高斯函数的叠加。左侧子图给出各策略下的重建误差分布；右侧子图对比了实际误差与前文引入的预测误差，以验证预测方法的准确性。整体结果显示，叠加策略的相对误差特征介于两种单一策略之间，且预测误差能较好地反映真实重建误差的走势。

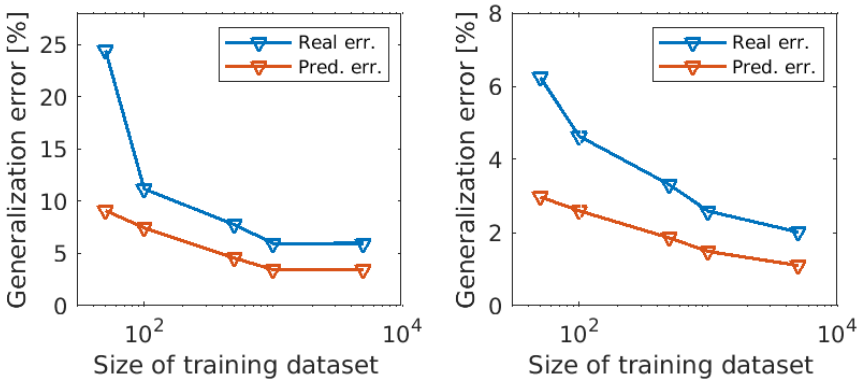


图 4.8: 展示了训练集大小与模型在留出测试集上泛化误差之间的关系。(a) 和 (b) 分别对应两种不同策略生成的训练集。随着训练样本增加，误差总体下降，但下降速度与稳定性因策略而异，反映了数据生成方式对模型泛化性能的影响。

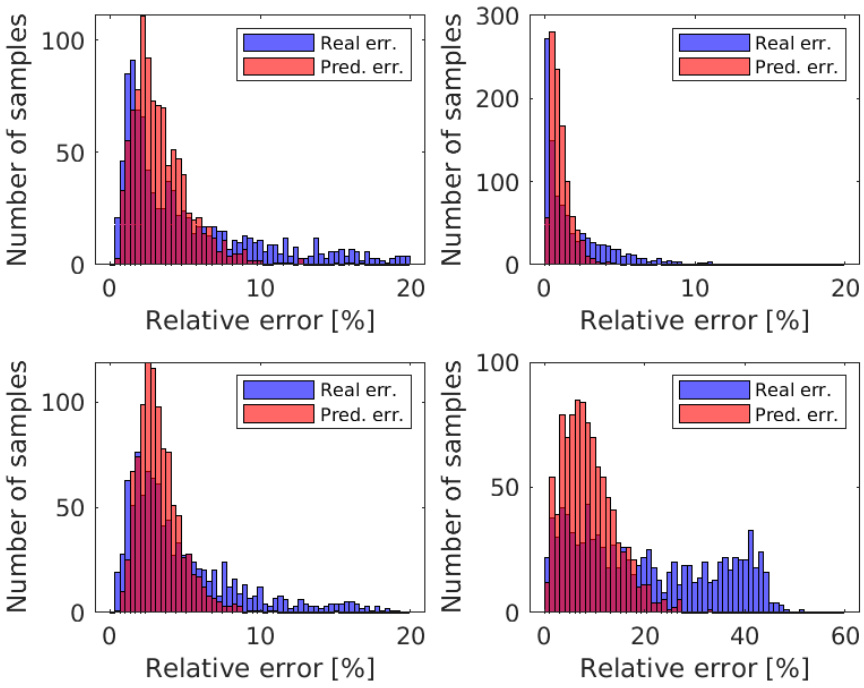


图 4.9: 展示了在不同训练集生成策略下训练的神经网络模型，分别在各自留出测试集和随机超高斯测试集上的相对误差分布。图中每一列代表一种训练集生成策略，同一列的两个子图使用相同的训练集；第一行子图为留出测试集上的结果，第二行子图为随机超高斯测试集上的结果。通过比较同一列上下两行，可以评估模型对训练数据分布的依赖程度及其对超高斯分布的泛化能力；通过比较同一行不同列，可以分析不同训练集生成策略对误差分布的影响。

第五章　实际问题中的应用

在基于深度神经网络的电子速度分布函数（EVDF）反演方法中，训练数据与真实实验数据之间的差异——即所谓的“模拟-现实鸿沟”（sim-to-real gap）——是制约模型实际应用效果的核心因素。训练集完全基于理想化的物理模型生成：散射光谱由解析理论精确计算，不含任何测量噪声，光谱仪响应被假定为理想状态，等离子体参数也在预设的随机范围内均匀采样。然而，真实的实验测量光谱不可避免地受到各类非理想因素的影响：光电探测器的暗电流与读出噪声、光谱仪的有限分辨率与像差、背景韧致辐射与杂散光的干扰、探针光强度的抖动以及等离子体参数的时空不均匀性。这些因素在训练集的生成过程中无法完全建模，导致模型在模拟数据上表现优异，却可能在面对真实实验光谱时产生意料之外的偏差。

因此，仅依靠同分布测试集上的误差统计来评估模型的可靠性是远远不够的。同分布测试集尽管在生成策略上与训练集有所区分，但本质上仍来自相同的理想化物理模型，其与真实实验数据之间仍存在系统性的鸿沟。更具说服力的验证方式是采用独立的数据源进行泛化测试：一方面，利用 PIC 模拟产生的数据——尽管仍属模拟范畴，但其包含了非平衡动力学过程的复杂特征，可检验模型对超出训练集物理机制的泛化能力；另一方面，将模型直接应用于已发表的实验测量数据，考察其重建结果是否与已知的物理预期相符。这类跨分布的泛化测试能够真实反映模型在面对 sim-to-real gap 时的稳健性，是判断该方法是否具备实际诊断应用价值的前提条件。若模型在这些分布外数据上仍能给出合理的重建结果，则说明模型确实学习到了从散射光谱到 EVDF 的稳健映射关系，而非仅在高维空间中记忆了训练集附近的局部结构。因此接下来我们采用了逆韧致吸收的实验数据和拉曼散射的 PIC 模拟数据进行测试.

5.1　逆韧致吸收实验数据的重建

5.1.1　逆韧致吸收理论

逆韧致吸收是激光等离子体相互作用中能量耦合的核心机制之一，其本质是电子在激光电场中振荡并通过碰撞将有序动能转化为随机热能。早在上世纪

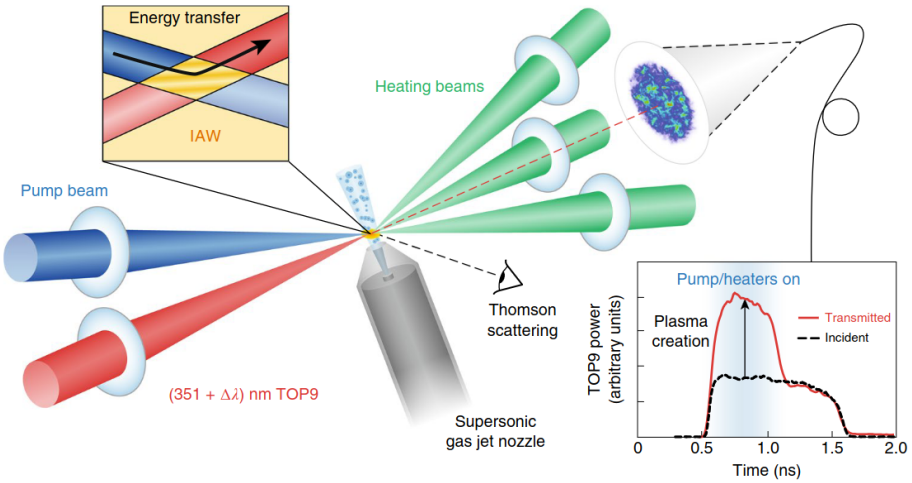


图 5.1: TOP9 实验平台示意图。超声速喷嘴向靶室中心前方 1.3 mm 处喷射氮氢混合气体。九束直径均为 850 μm 的加热光束以近准对称方式对气体进行电离和加热，持续约 500 ps。随后 500 ps 内，单束泵浦光与 TOP9 光束（相对泵浦光具有波长偏移 Δλ）同时开启，二者之间通过离子声波（IAW）介导能量转移。在此期间，可额外开启与 TOP9 近反向传播的加热光束，以增强朗登（Langdon）效应；这些附加光束因波长与几何配置，与泵浦光和 TOP9 的相互作用可忽略。最后 500 ps 内，仅保留 TOP9 光束，用于测量基线等离子体透射率。TOP9 最终入射至薄漫射片，透射信号由电荷耦合器件（CCD）相机及光纤耦合条纹相机记录（示例见插图）。实验通过上述时序，分阶段表征了多光束耦合、非局域加热及等离子体状态演化。[36]

八十年代，Langdon 即指出 [19]，这种加热过程并非各向同性地作用于所有电子，而是优先加热低能电子，因为低能电子具有更大的碰撞频率，从而更有效地从激光场中汲取能量。这种选择性加热使得电子速度分布函数偏离麦克斯韦–玻尔兹曼平衡形式，演化为高能尾部相对增强、低能区被削弱的超高斯分布，其形状由超高斯指数 m 刻画，m=2 对应麦克斯韦分布，m=5 则为强加热极限 [19, 38]。这种非平衡分布不仅影响吸收率，还通过改变电子对离子声波的屏蔽效率，使离子声波频率随 m 增大而单调上升，从而直接调制受激布里渊散射和交叉束能量转移的共振条件。

5.1.2 实验参数和汤姆逊散射诊断

为在可控条件下验证该效应对交叉束能量转移的影响，引用文献中的实验依托罗切斯特大学激光能量学实验室的 OMEGA EP 装置及其可调谐紫外光束

TOP9 开展。TOP9 基于光学参量放大前端，可在 350.2 nm 至 353.4 nm 范围内连续调谐波长，脉冲宽度最高 1 ns，输出功率约 0.5 TW。实验采用超音速气体喷嘴产生直径 2 mm 的射流，其出口处混合 45% 氮气和 55% 氢气，完全电离后有效电荷 $Z_eff = 6.11$　　9　850μm FWHM）加热光束以准对称方式在靶室中心重叠，每束能量约 180 J，持续 500 ps，将气体预电离并加热至约 0.8–1.1 keV。随后 500 ps 内，一束泵浦光（能量 70 J，功率 127 GW）与 TOP9（功率 10 GW）以近乎共线方式交叉，两者夹角 21.41°，泵浦光频率略高于 TOP9，使能量从泵浦转移至 TOP9。为增强 Langdon 效应，可额外引入数束近乎对向传播的加热光束，它们几乎不与泵浦和 TOP9 发生共振能量转移，但显著提高重叠区域的激光强度，从而增大　值。每发实验中 TOP9 的波长偏移量被改变，以扫描离子声波共振曲线。最后 500 ps 泵浦关闭，仅保留 TOP9，用于测量等离子体透射基线。

汤姆逊散射诊断是表征电子分布函数和等离子体参数的核心手段。其收集系统采用施瓦茨席尔德物镜，由两枚同心球面反射镜组成，后接普丰德物镜，将从靶室中心约 100 μm 体积内散射的光信号高效率传输至两台条纹光谱仪。为同时覆盖电子等离子体波和离子声波特征，系统分为两路：离子声波特征通过一台 1 m Czerny-Turner 光谱仪（光栅 2160 线/mm）测量，光谱分辨率 0.02 nm，时间分辨率 200 ps；电子等离子体波特征则通过一台 0.3 m 光谱仪（光栅 150 线/mm）测量，光谱分辨率 0.5 nm，时间分辨率 50 ps，并在其光路中插入光谱陷波滤光片以避免离子声波信号饱和条纹相机。散射几何固定，收集角分别对应不同加热光束的散射角（约 101.7°、102.8° 和 141.1°），多光束贡献按其在收集体积内的相对强度加权叠加。在数据处理中，理论光谱基于无碰撞谱密度函数计算，其中电子分布函数设为超高斯形式（m 为自由参数），离子分布函数假定为麦克斯韦，电子极化率通过对超高斯分布函数的斜率数值积分得到。拟合时，电子等离子体波特征主要用于约束电子密度、电子温度和 m 值，而离子声波特征则用于确定离子温度以及电子-离子相对漂移速度（以解释斯托克斯与反斯托克斯峰的不对称性）。通过变化入射激光束数量（从 1 束至 4 束，每束强度 $5.1\times10^14 W/cm^2$　　m 2.40　2.85 $Langdon$　　$TOP9$　　CCD

5.1.3　基于神经网络分析实验数据

我们利用已发表的实验数据对 DNN 模型进行了测试。该实验首次在惯性约束聚变相关条件下证实了 Langdon 效应——逆韧致吸收加热导致电子速度分

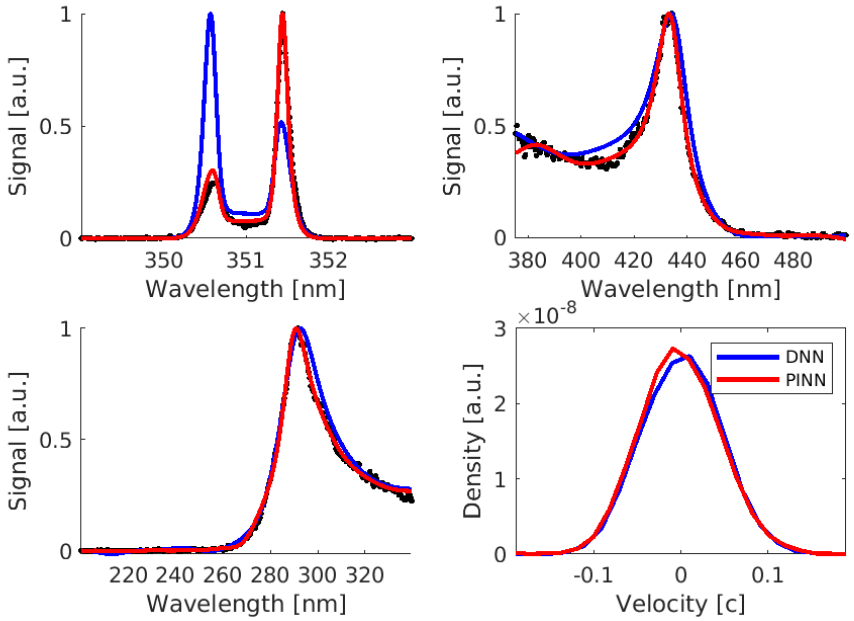


图 5.2: 利用深度神经网络（DNN）与物理信息神经网络（PINN）重建实验测量光电子能谱（OTS）的结果。重建得到电子速度分布函数（EVDF）后，基于该 EVDF 理论计算对应的 OTS 光谱，并与实验测量值进行对比。(a–c) 分别给出 OTS 的离子谱、红端电子谱和蓝端电子谱。其中黑色圆点为实验数据，蓝色和红色实线分别为 DNN 和 PINN 的重建结果。(d) 为重建的 EVDF，蓝色和红色线同样分别来源于 DNN 与 PINN。通过对比可见，两种方法均能较好地再现实验 OTS 谱线，且 PINN 在约束物理规律后重建的 EVDF 与理论预期更为一致。

布函数偏离麦克斯韦分布，呈现超高斯形态。研究表明，非麦克斯韦电子分布函数模型是解释交叉光束能量转移的必要条件，而标准的麦克斯韦计算会显著高估功率转移。

在原始实验的 OTS 光谱分析中，等离子体参数通过拟合获得：电子分布函数假定为超高斯形式，对应的电子极化率通过数值计算后代入无碰撞谱密度函数。拟合过程中，电子 OTS 光谱约束电子密度、电子温度和超高斯阶数；离子 OTS 光谱约束离子温度和电子-离子相对漂移速度。拟合结果表明，非麦克斯韦模型能同时完美匹配电子等离子体波和离子声波特征峰；而在麦克斯韦假设下，即使调整等离子体参数，这两个特征也无法同时重现。

我们将 DNN 直接应用于该实验的测量光谱，反演得到 EVDF，如图 5.2所示。然而，从反演 EVDF 正算得到的 OTS 光谱与实验测量光谱之间存在一定

差异。这是由于 OTS 光谱对 EVDF 的高频特征极为敏感，因此光谱上的误差可能远大于 EVDF 本身的误差。为确保重建精度，我们还采用了物理信息神经网络（PINN）进行光谱重建，获得了与实验测量足够接近的 OTS 光谱，结果亦绘于图5.2中。需要指出的是，在我们的测试中 PINN 的稳定性远不如当前的 DNN，对大多数非麦克斯韦 EVDF 无法给出合理的重建结果。然而，由于 PINN 在重建过程中直接比较反演 EVDF 的 OTS 光谱与目标光谱，一旦通过 PINN 获得合理的重建，其对应的 OTS 光谱必然与目标光谱非常接近。

5.2　受激拉曼散射超热电子的 PIC 模拟重建

受激拉曼散射（Stimulated Raman Scattering, SRS）是激光等离子体不稳定性（LPI）的重要形式之一。在 SRS 过程中，等离子体波形成的纵向电场会加速与其同向运动且速度相当的电子，使其成为高能电子（热电子）。现有技术只能在热电子离开等离子体后进行离线诊断，而 OTS 提供了原位诊断的可能性。当电子沿激光传播方向运动时，其汤姆逊散射光发生多普勒频移，频移量正比于电子速度。由于热电子运动速度远大于背景电子，它们在光谱的两端产生可分辨的红移和蓝移信号。

为模拟这一场景，我们开展了 PIC 模拟，模拟空间沿 x 方向长度为 50 um，网格尺寸为 4 nm。模拟时间分别为 1.2 ps。模拟包含等离子体和离子，二者数密度均设为 $8.144e26m^{-}3$；电子温度 1e3 eV，粒子数 5000；离子是氢离子，离子温度 0.5e3 eV，粒子数 50。泵浦光是连续光，归一化振幅 a0=0.02，波长 351 nm，偏振态为 y 方向线偏振。参数设定使热电子数密度约为背景电子密度的 0.1% 至 1%。为捕捉这一特征，我们对原始训练集进行了增强：在 EVDF 上叠加一个弱随机高斯分布以模拟热电子，其高度、宽度和中心位置在指定范围内随机选取。图 5.3(a) 比较了增强前后的 EVDF。

如图 5.3(b) 所示，在增强数据集上训练的模型能够准确重建热电子成分。值得强调的是，虽然在训练过程中仅使用高斯分布表示热电子，但模型成功地将这一特征推广至 PIC 模拟中前向和后向传播的热电子的重建。图 5.3(c) 展示了不同时刻的重建结果，与 PIC 模拟的 EVDF 吻合良好。图 5.3(d) 给出了前向传播热电子数密度的时间演化，OTS 重建结果与 PIC 模拟结果一致。

我们还考察了光谱测量噪声对重建的影响。如图 5.4所示，向 OTS 光谱添加不同程度随机噪声后直接输入训练好的模型，重建 EVDF 的误差始终保持在

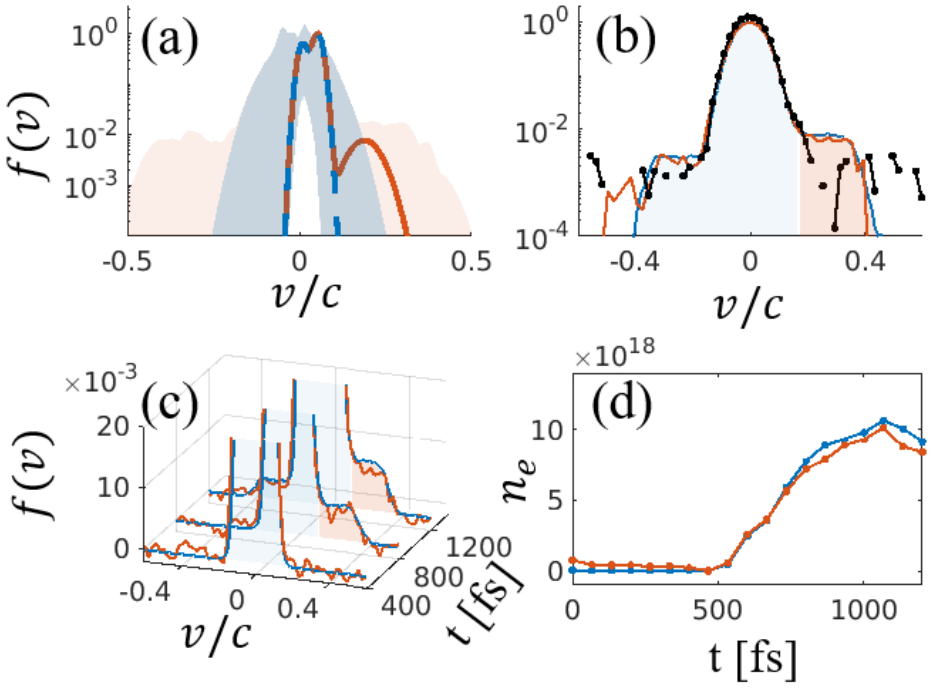


图 5.3: 含热电子的电子速度分布函数（EVDF）重建。(a–c) 的纵轴为归一化电子数密度，速度分布最大值归一化为单位量。(a) 给出训练集中一个 EVDF 样本在增强前（蓝色曲线）与增强后（红色曲线）的变化，蓝、红阴影区域分别代表训练集所有样本增强前、后的平均 EVDF，增强处理在保持主体分布的同时，提高了高能尾部的统计代表性。(b) 比较了 PIC 模拟的 EVDF（蓝线）与分别基于增强数据（红线）和未增强数据（黑线）训练的 DNN 重建 EVDF，可见增强数据训练的 DNN 与模拟结果更为接近，尤其能更好地重现热电子区域。(c) 展示了使用增强数据库训练的 DNN 在不同时刻重建的 EVDF（红线）与 PIC 模拟结果（蓝线）的对比，红色阴影区为热电子贡献，重建分布在各时刻均能与模拟结果保持一致。(d) 给出了前向传播热电子的时间演化，其中蓝线和红线分别来自 PIC 模拟和 DNN 重建，两者在整体演化趋势和幅度上吻合良好。综上，该图表明基于增强数据库训练的 DNN 能够有效重建含热电子的 EVDF，并能较好捕捉其动态演化过程。

可接受范围内。这一鲁棒性源于训练集仅包含无噪声的干净 OTS 光谱。与梯度下降法重建不同——后者会不加区分地拟合光谱中的每一个细节包括噪声——我们的神经网络模型在面对含噪测试光谱时，倾向于滤除训练集中不存在的噪声相关特征，而依赖在训练数据中大量出现的特征。因此，神经网络方法天然具备对测量噪声的免疫能力。

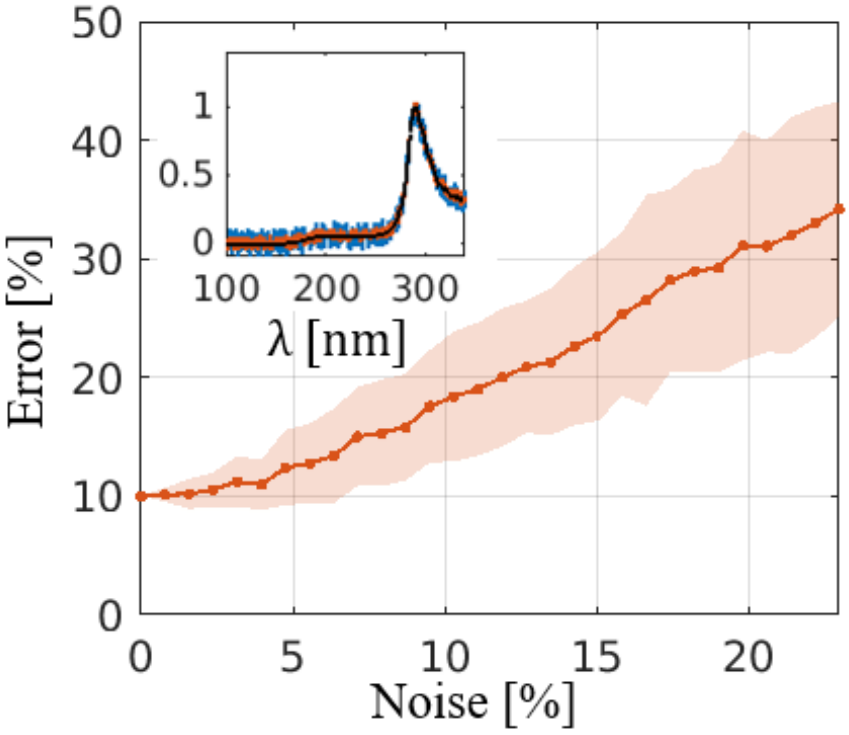


图 5.4: 不同噪声水平下热电子数目预测相对误差的统计结果。红色曲线表示相对误差的均值，红色区域表示标准差；每个噪声水平下均基于 700 次不同的电子速度分布函数（EVDF）与随机噪声迭代计算获得。插图展示了蓝电子峰（e ）在噪声水平分别为 0、10%、20% 时的光学瞬态光谱（OTS）对比，用于直观显示噪声对谱形及后续热电子预测的影响。随着噪声水平增加，相对误差的均值与标准差均呈增大趋势，反映预测不确定性的累积。

第六章　结论

本文系统介绍了基于大神经网络从光学汤姆逊散射光谱反演非麦克斯韦电子速度分布函数的方法。该方法以 EVDF 的傅里叶变换作为神经网络输出，通过大规模、多样化的训练数据集让模型学习从光谱到 EVDF 的逆映射。主要结论如下：

在模型架构方面，两层全连接 DNN 的表现优于 CNN 及更深层的 DNN，这源于 OTS 光谱不具备 CNN 所依赖的平移不变性，而更深层网络则受困于梯度消失问题。重建质量可通过简单增加模型参数量持续提升，并满足经验标度律 L=0.3678/N0.2685L=0.3678/N0.2685。

在泛化能力方面，重建误差与测试 EVDF 到训练集的最短距离密切相关，这为预测模型在未知数据上的表现提供了实用工具。模型对五高斯叠加、随机超高斯及混合叠加等多种未见过的 EVDF 类型均展现出良好的泛化能力，重建误差保持在 5% 以内。

在实际应用方面，模型成功应用于逆韧致吸收实验数据，反演得到的 EVDF 与 Langdon 效应的理论预期一致；在 SRS 超热电子的 PIC 模拟数据上，模型准确重建了热电子成分及其时间演化，且对光谱测量噪声具有天然鲁棒性。单次推理仅需约 1.5 ms，为未来 OTS 诊断的实时在线分析奠定了技术基础。

致 谢

感谢国家自然科学基金、中国博士后科学基金、上海交通大学物理与天文学院对研究工作的资助。

参考文献

[1] B. Bai, J. Zheng, W. Liu, et al. Thomson scattering measurement of gold plasmas produced with 0.351 m laser light. *Physics of Plasmas*, 9:4144–4148, 2001.

[2] K. Bi, L. Xie, H. Zhang, et al. Accurate medium-range global weather forecasting with 3d neural networks. *Nature*, 7970:533–538, 2023.

[3] R. M. Cichy and D. Kaiser. Deep neural networks as scientific models. *Trends in Cognitive Sciences*, 4:305–317, 2019.

[4] D., H., Froula, et al. Thomson-scattering measurements of high electron temperature hohlraum plasmas for laser-plasma interaction studies. *Physics of Plasmas*, 5:052704, 2006.

[5] A. Farea, O. Yli-Harja, and F. Emmert-Streib. Understanding physics-informed neural networks: Techniques, applications, trends, and challenges. *AI*, 3:1534–1557, 2024.

[6] R. K. Follett, J. A. Delettrez, D. H. Edgell, et al. Plasma characterization using ultraviolet thomson scattering from ion-acoustic and electron plasma waves (invited). *Review of Scientific Instruments*, 11:11E401, 2016.

[7] D. H. Froula, S. H. Glenzer, N. C. Luhmann, et al. Plasma scattering of electromagnetic radiation: Theory and measurement techniques. *Fusion Science and Technology*, 1:104–105, 2012.

[8] L. Giudicotti, R. Pasqualotto, and A. Fassina. Dual-angle, self-calibrating thomson scattering measurements in rfx-mod. *Review of Scientific Instruments*, 11:11D823, 2014.

[9] T. Gong, Z. Li, X. Jiang, et al. Development of thomson scattering system on shenguang-iii prototype laser facility. *Review of Scientific Instruments*, 2:023501, 2015.

[10] T. Van Hoomissen, J. Alhuthali, A. M. Ortiz, et al. Transfer learning for analysis of collective and non-collective thomson scattering spectra. *Physics of Plasmas*, 1:013903, 2026.

[11] A. Jalalvand, S. Kim, J. Seo, et al. Multimodal super-resolution: discovering hidden physics and its application to fusion plasmas. *Nature Communications*, 1:8506, 2025.

[12] A. Jalalvand, S. Kim, J. Seo, et al. Multimodal super-resolution: discovering hidden physics and its application to fusion plasmas. *Nature Communications*, 1:8506, 2025.

[13] S. Joung, J. Kim, D. R. Smith, et al. Explainable tokamak-agnostic forecasting of fusion plasma instability via megahertz turbulent fluctuations. *Communications Physics*, 2026.

[14] J. Jumper, R. Evans, A. Pritzel, et al. Highly accurate protein structure prediction with alphafold. *Nature*, 7873:583–589, 2021.

[15] Jared Kaplan, Sam McCandlish, Tom Henighan, et al. Scaling laws for neural language models. arXiv:2001.08361, 2020.

[16] J. Kates-Harbeck, A. Svyatkovskiy, and W. Tang. Predicting disruptive instabilities in controlled fusion plasmas through deep learning. *Nature*, 7753:526–531, 2019.

[17] S. K. Kim, R. Shousha, S. M. Yang, Q. Hu, S. H. Hahn, A. Jalalvand, J.-K. Park, N. C. Logan, A. O. Nelson, Y.-S. Na, R. Nazikian, R. Wilcox, R. Hong, T. Rhodes, C. Paz-Soldan, Y. M. Jeon, M. W. Kim, W. H. Ko, J. H. Lee, A. Battey, G. Yu, A. Bortolon, and E. Kolemen. Highest fusion performance without harmful edge energy bursts in tokamak. *Nature Communications*, 15(1):1, 2024.

[18] R. Lam, A. Sanchez-Gonzalez, M. Willson, et al. Learning skillful medium-range global weather forecasting. *Science*, 6677:1416–1421, 2023.

[19] A. Bruce Langdon. Nonlinear Inverse Bremsstrahlung and Heated-Electron Distributions. *Physical Review Letters*, 44(9):575–579, 1980.

[20] Mingze Li, Yu Rong, Songyou Li, et al. Agentic fusion of large atomic and language models to accelerate superconductor discovery. arXiv:2604.23758, 2026.

[21] Z. Li, J. Zheng, X. Jiang, et al. Interaction of 0.53 m laser pulse with millimeter-scale plasmas generated by gasbag target. *Physics of Plasmas*, 6:062703, 2012.

[22] Z. Lin, H. Zhang, F. Wang, et al. Prediction of plasma rotation velocity and ion temperature profiles in east tokamak using artificial neural network models. *Nuclear Fusion*, 10:106061, 2024.

[23] Y. Ling, J. Du, Z. Liu, et al. Pamma-net: plasmas magnetic measurement evolution based on data-driven incremental accumulative prediction. *Nuclear Fusion*, 10:106027, 2025.

[24] Y. Liu, Y. Ding, and J. Zheng. Improvement in thomson scattering diagnostic precision via fitting the multiple-wavenumber spectra simultaneously. *Review of Scientific Instruments*, 8:083501, 2019.

[25] C. J. McDevitt and X. Tang. A physics-informed deep learning description of knudsen layer reactivity reduction. *Physics of Plasmas*, 6:062701, 2024.

[26] A. Merchant, S. Batzner, S. S. Schoenholz, et al. Scaling deep learning for materials discovery. *Nature*, 7990:80–85, 2023.

[27] M. Pokornik, D. P. Higginson, G. Swadling, et al. A deep learning approach to fast analysis of collective thomson scattering spectra. *Physics of Plasmas*, 7:072115, 2024.

[28] D. Qiu, T. Minami, S. Kado, et al. Design of a dual scattering angle multi-pass thomson scattering system with signal separation function on heliotron j. *Review of Scientific Instruments*, 1:013503, 2023.

[29] M. Raissi, P. Perdikaris, and G. Karniadakis. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. *Journal of Computational Physics*, pages 686–707, 2019.

[30] J. Ross. *5 Optical Thomson Scattering Report*. Office of Scientific and Technical Information (OSTI), 2023.

[31] J. S. Ross, H. Park, P. Amendt, et al. Thomson scattering diagnostic for the measurement of ion species fraction. *Review of Scientific Instruments*, 10:10E323, 2012.

[32] S., H., Glenzer, et al. Thomson scattering from inertial-confinement-fusion hohlraum plasmas. *Physical Review Letters*, 7:1277–1280, 1997.

[33] Ayan Sengupta, Yash Goel, and Tanmoy Chakraborty. How to upscale neural networks with scaling law? a survey and practical guidelines. arXiv:2502.12051, 2025.

[34] W. Tan, Y. Liu, X. Li, et al. Electron density measurement via dual-angle thomson scattering diagnosis. *Journal of Applied Physics*, 4:043302, 2021.

[35] D. Turnbull, J. Katz, M. Sherlock, et al. Inverse bremsstrahlung absorption. *Physical Review Letters*, 14:145103, 2023.

[36] David Turnbull, Arnaud Colaïtis, Aaron M. Hansen, Avram L. Milder, John P. Palastro, Joseph Katz, Christophe Dorrer, Brian E. Kruschwitz, David J. Strozzi, and Dustin H. Froula. Impact of the Langdon effect on crossed-beam energy transfer. *Nature Physics*, 16(2):181–185, 2019.

[37] C. Wang, W. Yang, H. Wang, et al. Physics-informed deep learning model for line-integral diagnostics across fusion devices. *Nuclear Fusion*, 7:076022, 2025.

[38] Su-Ming Weng, Zheng-Ming Sheng, and Jie Zhang. Inverse bremsstrahlung absorption with nonlinear effects of high laser intensity and non-Maxwellian distribution. *Physical Review E*, 80(5):056406, 2009.

[39] H. Zhao, Z. Li, D. Yang, et al. Implementation of ultraviolet thomson scattering on sg-iii laser facility. *Review of Scientific Instruments*, 9:093505, 2018.

[40] H. Zhao, Z. Li, D. Yang, et al. Progress in optical thomson scattering diagnostics for icf gas-filled hohlraums. *Matter and Radiation at Extremes*, 5:055201, 2019.

[41] H. Zhao, Z. Li, D. Yang, et al. Progress in optical thomson scattering diagnostics for icf gas-filled hohlraums. *Matter and Radiation at Extremes*, 5:055201, 2019.

[42] W. Zheng, X. Wei, Q. Zhu, et al. Laser performance upgrade for precise icf experiment in sg- laser facility. *Matter and Radiation at Extremes*, 5:243–255, 2017.

[43] 李志超, 赵航, 龚韬, et al. 激光惯性约束聚变中光学汤姆逊散射研究进展. 强激光与粒子束, 9:092004, 2020.

简　历

基本情况

程先涛

教育状况

2011 年 9 月至 2015 年 7 月，西安交通大学，本科，专业：物理。

2016 年 8 月至 2023 年 12 月，德州大学奥斯汀分校，博士，专业：物理。

工作经历

2024 年 3 月至 2026 年 8 月，上海交通大学，博士后。

研究兴趣

激光等离子体相互作用，神经网络

联系方式

通讯地址：上海

E-mail: chengxiantao@utexas.edu