SPEC：通用 VDF 模型与数据接口、球形腔干净训练数据

设计草案 · PDF导出：2026-10-18 · 内容以对应Markdown为准

更新：2026-10-18。状态：设计，尚未实施。按用户要求经独立子 agent 范围审查及代码复用审查后修订。本轮只改文档，不修改代码，不生成正式数据或训练模型。

1. Requirements（需求）

只做两件事：

1. **通用模型和数据接口。** 现有 MLP、Fourier 标签和训练流程接受任意数量、种类及顺序的目标物种，以及任意数量、范围和点数的光谱段。一次训练的物种、坐标与维数固定，更换配置后重新训练。

2. **本任务专属数据生成。** 根据论文 Fig.1(a,b) 和已提取的 Fig.11 实验温度锚点，采样温度、密度、平均速度和分布形状，生成 e/H/C 的干净理论谱及对应 VDF，直接写成第一项接口能读取的训练数据，并接通现有训练循环。

“任意离子组分”指模型与数据接口可接受其他组分的数据；本任务内置生成器只负责 C5H12 的 e/H/C。现有 OTS_spectrum_PV 固定两个离子，本次不扩建通用多离子正向引擎。

不做实验/抠图数据反演、自动扣背景、mask、数据增强、敏感性分析、可辨识性报告、重复训练对照、新 CLI 或 registry。模型输入只有光谱，密度只是本任务的正向采样参数。保留现有任务、旧 Parquet 和旧 checkpoint 的行为。

完成标准是：本任务数据能够生成、保存、加载、训练、保存模型并重载预测；通用接口不把 e/H/C、319 点或 480 输出写死。这里的“跑通”是后续实施验收目标，不代表本轮已经执行。

2. Design（设计）

2.1 最小数据流与文件职责



文件	后续实施时的最小改动
vdf_data.py（新增）	普通字典配置、光谱拼接、NPZ/JSON 读写与 Fourier 标签
hohlraum_data.py（新增）	本任务锚点读取、VDF 采样、干净理论谱生成
model.py	MLP 首末层维数、逐物种 Hermitian 投影、最小模型加载/预测接口
train.py	去除训练核心中的固定维数；增加一个数据到既有 train_candidate 的薄入口
data.py	仅为既有 electron_moments 增加质量参数；直接复用 normalize_distribution

文件	后续实施时的最小改动
evaluation.py	仅参数化既有预测与逆 Fourier 数值函数；不增加评估业务流程

main.py、物理模块、旧 Parquet loader及现有 CLI 不改。新数据使用独立 NPZ。普通函数、字典、列表即可，不新增继承体系、任务注册、回调或插件机制。

复用边界：VDF归一化调用 data.normalize_distribution，矩计算调用增加质量参数后的 data.electron_moments；Fourier/PV直接使用现有函数；模型统计校验复用 _validate_checkpoint_tensor；预测/逆变换复用 evaluation 的数值函数；划分只保留一份索引算法。旧热电子采样范围、固定离子生成器和带背景的Maxwellian拟合不适合本任务，不硬套。NPZ读写与Fig.11筛选只保留必要适配。

2.2 通用数据与模型约定

配置 contract 仅包含：

字段	内容
bands	有序列表：name, wavelength_nm；每段至少2点、有限且严格递增
species	有序列表：name, mass_kg, charge, v_grid_m_s, k_grid_s_m；物种名称唯一，质量为正，各自速度轴固定、近似等间距且至少3点
fourier_modes	共同模式数 M，默认80；M为不小于2的整数且不超过任一速度轴点数

species 是网络实际输出的完整有序列表，可包含电子及任意离子；数据接口不判断这些物种应由哪个正向程序生成。电荷以基本电荷为单位，质量用 kg，速度用 m/s，Fourier K 用 s/m，波长用 nm。

令 L=sum(len(band.wavelength_nm))，S=len(species)：

• 输入维数 D_in=L，只拼接各段光谱；无 mask、密度或其他附加特征。

• 输出维数 D_out=2*M*S，第 s 块为 [Re(F_s), Im(F_s)]。

• 每段只做 spectrum/max(abs(spectrum))，保留整段相对峰高；不扣背景、不平滑。全零或非有限谱直接报错。

• 每种 VDF 在自己的固定速度轴上积分为1。K轴由现有 ft_x_n 生成，不能手写另一套 Fourier 约定。

• Hermitian 投影在每个物种的 M 个模式内执行，不跨物种翻转。

• 任意波段/物种指可配置，不是同一模型逐样本改变长度。模型保存这些坐标和顺序。

数据仅有两个同名文件：

• dataset.npz：x[N,L]、y[N,2*M*S]、f_0[N,Nv_0] … f_{S-1}[N,Nv_{S-1}]。x/y 为 float32，原始 VDF 为 float64。每行是一份独立物理样本，无 metadata 行、sample_id 或 group_id。

• dataset.json：contract 和 sampling。后者只记录本任务锚点、采样范围、几何、仪器参数及 seed；外部数据可留空。读取使用数组，不用 pickle 对象数组。

JSON坐标保存为普通列表，读回转为数组；x/y的数值一致性检查使用float32对应的容差。

本任务默认输入319点、输出 e/H/C 三组80复系数，即 **319 → 480**。更多波段直接增加 L，更多目标物种直接增加 S；无需修改网络定义。

2.3 Fig.1 与 Fig.11 锚点

论文：Hang Zhao et al., *Progress in optical Thomson scattering diagnostics for ICF gas-filled hohlraums*, DOI:10.1063/1.5090971。

Fig.1 锚点	时间 ns	Te eV	共同 Ti eV	ne cm^-3	ui m/s	ue m/s
(a)	2.0	209	78	3.5e20	-640	-1.4e5

Fig.1 锚点	时间 ns	Te eV	共同 Ti eV	ne cm^-3	ui m/s	ue m/s
(b)	4.3	1392	912	4.0e20	1.4e4	-1.2e5

Fig.11 直接读取已有文件，不重新提取：

C:/Users/win/.codex/worktrees/74c1/ots/outputs/ots_experimental_fits/fig6_fig11_shared_ne6e20_20260921/paper_experimental_points.csv

选择 figure=fig11, shot_id=20170811020，parameter=T_e_ev 的27点与 parameter=T_i_ev 的27点分别组成温度锚点池，使用 point_id/value。不把54个读数称为54组温度对，不读取旧拟合值作标签，不引入温度曲线提取任务。

每个样本均匀选择29个电子温度中心之一（Fig.1两点及Fig.11的27点）：选到Fig.1时采用同一点的 Ti 中心和密度范围；选到Fig.11时独立抽取其 Ti 池中的一个中心。后者用于温度范围采样，不保留时间配对关系。论文共同 Ti 作为 TH、TC 的共同中心，两种离子温度随后独立变化。

参数	变体采样规则
Te	max(20, Te0*exp(U(log(0.6),log(1.5)))) eV
TH、TC	分别独立取 max(10, Ti0*exp(U(log(0.5),log(1.8)))) eV
ne，Fig.1(a)	U(0.8,1.2)*3.5e20 cm^-3
ne，Fig.1(b)	U(3,5)*1e20 cm^-3
ne，Fig.11	U(2.8,5)*1e20 cm^-3；这是采样范围假设，不是各时刻密度测量
uH、uC	先抽公共 ui~U(-2e4,3e4)，再分别加 U(-5e3,5e3) m/s
ue	U(-2.5e5,0.5e5) m/s

这些范围可通过本任务配置修改；它们是物理样本的变体范围，不是向光谱添加噪声或背景。

2.4 一维 VDF 与干净理论谱

输出是名义散射方向 khat0=(ss-k_sh)/|ss-k_sh| 上的一维实验室系 VDF。按用户决定，当前窄 IAW 窗口采用固定方向近似，不做三维投影、方向缓存或额外漂移几何对照。

每个物种独立抽取形状族：40% 单 Gaussian，40% 三 Gaussian 混合，20% 一维超高斯。

• 混合：归一化 Gaussian 的面积权重 Dirichlet(2,2,2)，中心 U(-1,1)，标准差 U(0.7,1.4)。

• 超高斯：直接定义一维 exp(-|q|^p)，p~U(2,4)；它不是三维各向同性超高斯的投影。归一化常数为 p/(2*Gamma(1/p))，方差为 Gamma(3/p)/Gamma(1/p)。

• 先将形状规范为零均值、单位方差 h，再在固定速度轴上求 f(v)=h((v-u)/sigma)/sigma，sigma=sqrt(e*T/m_s)，最后数值积分归一化。保存原始 VDF，同时用 ft_x_n 生成标签。

• 每物种默认4097点，区间 ±(max_abs_u+8*sqrt(e*T_max/m_s))，由锚点及采样上界一次确定；不随样本改变网格。

本任务物理条件固定为：探针263.3 nm、散射角90°、H:C数目比12:5、Z_H=1、Z_C=6、质量使用现有模块的 m_e,m_p,12*m_p。准中性给出 nH=(2/7)*ne, nC=(5/42)*ne；PV参数 N_i1/N_i2 使用12/17和5/17，ne由cm^-3乘1e6转为m^-3。方向取 k_sh=(1,0,0), ss=(0,1,0)，E_i0=(0,0,1)，体积为 (100e-6)^3 m^3；归一化光谱不恢复绝对功率。

VDF均值已在f内，调用现有PV时三套外部漂移均为零。生成及Fourier计算显式float64。

默认波长轴沿用已提取Fig.10(b)的319点，端点262.31242236024843–264.2875776397516 nm；配置可指定其他轴。仪器只使用固定Gaussian FWHM=0.057 nm：在每段两侧多算 8*sigma_lambda，sigma_lambda=FWHM/2.355，内部等间距步长不大于0.002 nm；用单位面积核卷积后，直接插值到目标轴并整段归一化。不经过实验或图像的中间采样轴。卷积直接使用NumPy的 convolve 与离散权重和为1的Gaussian核；不另建卷积模块，也不套用旧拟合器在有限窗口逐行重归一的卷积以改变边界含义。

一份样本就是“一组物理参数和三套VDF → 一组干净理论谱”，不加入背景、随机幅度、噪声、色标误差、配准或缺测。所有形状和物理参数每行独立抽取，不建设基准形状缓存。

2.5 接通现有训练的最小改动

新增 train_vdf 仅负责加载NPZ、调用从旧函数抽出的 split_indices 做行级train/validation划分、计算统计和创建DataLoader，然后调用现有 train_candidate。旧 split_train_validation 也调用同一个索引函数，不再复制randperm/round/clamp逻辑。新入口不包含batch更新或epoch循环，也不复制优化器、调度和早停实现。复用现有 run_epoch、coefficient_loss、AdamW及早停逻辑，只把固定维数改成参数或从张量推导。

本任务一次配置一个网络，默认隐藏层1024×512、dropout=0；不新增候选搜索、多seed比较或独立评估流程。train/validation默认90%/10%，输入输出统计只用training部分。其余训练参数复用现有 resolve_training_config。

模型文件 vdf_model.pt 只保存：model_state, hidden_sizes, dropout, contract, x_mean, x_scale, y_mean, y_scale, dtype, training_config, best_epoch, best_validation_loss, history。dtype为本任务训练的float32，供既有预测函数读取。与旧 model.pt 分开加载；输入/输出维数从contract推导。预测只做原有反标准化、逐物种Hermitian投影和逆Fourier，不裁负、不额外拟合。

3. 具体接口与伪代码

以下仅列拟新增/修改的函数。其他函数接口保持不变；本节是后续实现说明，不是本轮代码变更。

3.1 vdf_data.py

D1 resolve_contract(bands: list[dict], species: list[dict], fourier_modes: int=80) -> dict

```
检查非空列表、唯一名称、波长轴、各物种质量/电荷与固定速度轴
对每种v调用ft_x_n(v, zeros_like(v), M)，取得K；若传入K则核对
返回只含bands/species/fourier_modes的普通字典；L/S及切片按列表长度推导
```

D2 pack_spectra(spectra: list[ndarray], contract: dict) -> ndarray

```
按bands顺序检查数量、各段最后一维长度及相同batch维；拒绝非有限或全零谱
每段沿最后一维除以max(abs(spectrum))，再沿最后一维拼接
返回[..., L]；不插值、不扣背景、不添加特征
```

D3 write_vdf_dataset(path: Path, spectra: list[ndarray], vdfs: list[ndarray], contract: dict, sampling: dict | None=None) -> None

```
拒绝覆盖已有文件；校验每段[N,L_b]和每物种[N,Nv_s]，样本数相同
检查VDF有限、非负且积分约1；x=D2(spectra,contract)
逐行逐物种调用ft_x_n，核对K并按[Re,Im]顺序拼接为y
保存NPZ的x/y及f_s；同名JSON保存contract和sampling
```

D4 load_vdf_dataset(path: Path) -> dict

```
读取同名JSON并用D1核对contract；np.load(...,allow_pickle=False)
检查x/y/f_s形状、finite、物种顺序与坐标；不猜旧Parquet格式
返回x/y的CPU float32 Tensor、VDF数组列表、contract及sampling
```

3.2 hohlraum_data.py

H1 load_hohlraum_anchors(points_csv: Path) -> dict

```
用标准库csv读取2.3指定Fig.11/shot/parameter的point_id和正温度value
得到Te/Ti两个非空列表，加入硬编码的Fig.1(a,b)两条精确记录
返回fig1、fig11_Te、fig11_Ti及来源路径；不做时间配对、提图或拟合
```

H2 sample_vdf(v: ndarray, mass_kg: float, temperature_ev: float, mean_m_s: float, rng: Generator) -> ndarray

按2.4概率抽形状；Gaussian混合解析求均值方差，超高斯用Gamma公式
把形状规范为h(z)；在传入的固定v上计算h((v-u)/sigma)/sigma
调用data.normalize_distribution(v,values,name)完成归一化与有限/非负检查
调用data.electron_moments(...,configured_ev=T,mass_kg=mass_kg)核对实际均值/温度
返回f的float64 ndarray；不再写第二套积分归一化或矩公式

H3 generate_hohlraum_sample(anchors: dict, contract: dict, config: dict, rng: Generator) -> tuple[list[ndarray], list[ndarray]]

确认本任务species顺序为e/H/C及对应质量/电荷；按2.3抽中心和Te/TH/TC/ne/u
逐物种用H2生成VDF；按2.4构造float64 PV参数，外部漂移全零
逐band调用既有OTS_spectrum_PV，用np.convolve及固定归一Gaussian核展宽后直接插值到目标轴
返回有序光谱列表与VDF列表；不生成任何观测扰动

H4 generate_hohlraum_dataset(points_csv: Path, output_path: Path, sample_count: int, seed: int, config: dict) -> dict

H1读取锚点；按采样上界确定固定v轴，配置bands及e/H/C后调用D1
建立rng(seed)，循环sample_count次H3；按band/species分别堆叠
D3保存数据，sampling记录锚点、采样参数、几何/仪器与seed
返回dataset_path及contract；不自动启动训练

3.3 model.py

M1 OTSRegressor.__init__(hidden_sizes, dropout, *, input_dim=1224, output_dim=160)

校验正整数维数；仅把现有首层/末层Linear的维数换成参数
LayerNorm/激活/初始化及state_dict名称保持原样；forward不变

M2 hermitian_project(coefficients: Tensor, *, fourier_modes: int=80) -> Tensor

要求末维为2*M的正整数倍；reshape为[..., S, 2, M]
各物种Re与翻转的Re平均，Im与翻转的Im反对称平均
恢复输入形状；默认160维的数值行为与旧函数一致

M3 load_vdf_checkpoint(path: Path, device: str='cpu') -> dict

加载本任务payload，D1核对contract并推导L及2MS
复用model._validate_checkpoint_tensor检查x/y统计量长度、finite与正scale
按隐藏层及推导维数构造M1，strict加载权重，eval
返回含model及原payload字段的字典；不改旧load_model_checkpoint

M4 predict_vdfs(loaded: dict, spectra: list[ndarray], contract: dict, *, batch_size: int=128) -> list[ndarray]

核对传入contract的物种/波段顺序及v/K/波长轴与模型一致；不只比较维数
spectra必须已位于这些轴上；D2拼接后转float32 Tensor，单条样本补batch维
函数内导入R2/R3以避免model/evaluation顶层循环导入
调用R3(model,x,loaded,batch_size,模型所在device,fourier_modes=M)
逐物种取2M系数块，调用R2(coeff_s,K_s,velocity=v_s)，转回ndarray
返回原始一维VDF列表；只提供数组接口，不读实验文件或生成报告

3.4 train.py

T0 split_indices(sample_count: int, fraction: float, seed: int) -> tuple[Tensor, Tensor]

原样承接旧split_train_validation的N/fraction/seed校验及局部Generator
randperm后以原round及上下限规则确定validation_count，返回train/validation索引
只移动既有算法，不改变随机数、舍入或排列顺序

T0b split_train_validation(dataset, fraction, seed)（签名不变）

保留旧OTSDataset类型与validate_dataset校验
调用T0后索引旧spectra/coefficients，保持原四个张量返回值

T1 normalization_statistics(x_train, y_train)（签名不变）

保留二维、同样本数、非空及finite检查，移除1224/160限制
沿用现有逐列均值/std及scale下限，返回原四个统计量

T2 coefficient_loss(predicted_normalized, target_raw, y_mean, y_scale, raw_loss_weight, *, fourier_modes=80)

从末维检查预测/标签/统计量一致，不再要求160
反标准化后调用M2(...,fourier_modes=M)
沿用现有standardized MSE与normalized raw MSE公式及权重

T3 run_epoch(model, loader, optimizer, device, statistics, config, training, *, fourier_modes=80)

保留现有batch循环、反传、裁剪及样本加权loss
仅向T2传fourier_modes；不改变其他计算顺序

T4 train_candidate(hidden_sizes, train_loader, validation_loader, device, statistics, config, *, input_dim=1224, output_dim=160, fourier_modes=80)

按input_dim/output_dim构造M1；两次调用T3时传fourier_modes
复用现有优化器、调度、epoch循环、早停、最佳权重保存和返回值

T5 train_vdf(dataset_path: Path, output_dir: Path, config: dict) -> Path

D4读数据；复制config，未指定candidates时设为[{hidden_sizes:[1024,512],dropout:0.0}]
resolve_training_config解析配置，要求恰好一个网络配置及至少两条数据
沿用choose_device/set_determinism；调用T0做90/10或配置比例行划分
T1仅统计training部分；标准化x，创建现有形式的TensorDataset/DataLoader
T4训练一次，传L/2MS/M；取返回的最佳state_dict及best_epoch/best_validation_loss/history
创建输出目录并保存2.5所列payload到vdf_model.pt，已有文件则报错
返回checkpoint路径；函数内不写epoch/batch循环，不读取测试或实验数据

后续实施后，最小调用链为 H4(...) -> T5(dataset_path, ...) -> M3(checkpoint) -> M4(loaded, spectra, contract)。旧 train_model 仍通过T4训练，依靠默认参数保持原1224/160/80行为，无需重写旧入口。

3.5 复用的现有数值函数：仅补参数

N1 data.electron_moments(v_e, f_e, configured_ev, *, mass_kg=ELECTRON_MASS) -> dict

保留旧名称、归一积分、均值/中心方差及返回键；检查新增质量为正且有限
仅将温度式中的固定ELECTRON_MASS改为mass_kg，默认结果不变
H2按物种传质量；不通过速度缩放或修改configured_ev绕用电子质量

R1 evaluation._validate_k_grid(k_grid, *, mode_count=80) -> Tensor

复用原finite/递增/近似等间距检查；形状80改为传入的mode_count
要求mode_count为不小于2的整数；旧调用仍默认80

R2 evaluation.reconstruct_real_evdf(coefficients, k_grid, *, velocity=None) -> tuple[Tensor, Tensor]

未传velocity时保留原80模式检查与速度轴构造；传入时M=len(K)，调用R1(mode_count=M)
检查coefficients为[N,2M]，指定velocity为有限递增的一维Tensor
复用原cos/sin基底、梯形权重与矩阵乘法，仅把Re/Im切片80换成M
M=2时dk取K[1]-K[0]；其他情况保留原K[2]-K[1]，返回velocity及VDF

R3 evaluation.predict_coefficients(model, spectra, checkpoint, batch_size, device, *, fourier_modes=80) -> Tensor

输入/输出维数从checkpoint的x_mean/y_mean长度取得，代替1224/160检查
复用原dtype、batch循环、标准化、no_grad、反标准化及finite检查
调用hermitian_project时传fourier_modes；旧checkpoint行为不变

4. Tasks（任务拆解）

编号	任务	依赖	可验证结果
1	实现D1-D4通用数据接口	无	不同波段及物种数可写入、读回且坐标/列顺序一致
2	参数化M1/M2、T1-T4；抽出T0并复用到T0b	无	任意L/S前向与loss可计算；旧划分及默认行为保持
3	实现H1-H4并复用归一化、参数化N1	1	Fig.1/Fig.11变体得到干净谱、VDF及Fourier标签
4	参数化R1-R3并实现T5、M3/M4薄适配	1、2	数据直接接现有训练，可保存、重载并输出VDF
5	完成下列最小验收	3、4	生成到重载预测的调用链实际跑通

5. Acceptance Criteria / Tests（验收标准）

1. **通用性**：至少检查单/双光谱段、两种不同总点数，以及S=1、3、4的合法数据；使用不同离子名称/质量/电荷。模型与数据函数不依赖H/C常量，各物种Hermitian投影不串块。同维数不同物种/坐标不能在加载数据或预测时被默认为同一配置。

2. **本任务数据**：复用已有27+27个Fig.11点及两条Fig.1记录；温度和密度采样符合2.3，TH/TC可独立变化。VDF归一化及实际矩与设定值在离散误差内一致；无背景、噪声、mask或图像处理分支。保存的y与保存VDF的Fourier变换一致。

3. **基本数值正确性**：用少量Gaussian样本对照现有解析Maxwellian谱；细化一次速度/波长网格确认理论谱稳定，并检查M=80的VDF往返误差。此项是普通数值验收，不建立pilot审批或报告体系。

4. **能跑通**：用小规模本任务数据完成加载、至少一次参数更新、validation、保存、重载及M4预测；loss有限，所有输出形状正确，重载前后的同批预测一致。不以未训练的设计文档宣称达到重建精度。

5. **兼容性与范围**：旧1224/160模型同权重预测、逆Fourier、默认电子矩及同seed划分保持不变；旧Parquet/checkpoint仍使用原接口。新增路径实际调用上述既有数值核心，不另写预测、逆变换、矩或划分算法。不修改现有物理公式，不添加实验反演、评估报告、CLI或registry流程。